

Kapitel 3
Einführung in R

V26-10-07

© 2026 – Hochschule der Bayerischen Wirtschaft

Agenda

1. Einführung
2. Grundlagen quantitativer Datenanalyse
3. **Einführung in R**
4. Explorative Datenanalyse
5. Die Normalverteilung
6. Hypothesentests
7. Lineare Regression
8. Die Hausarbeit

© 2026 – Hochschule der Bayerischen Wirtschaft

Einführung in R
Warum R?

- Verbreitung z. B.: http://r4stats.com/articles/popularity/
- **R ist eine weit verbreitete Eintrittskarte in das globale Datenzeitalter!**

Vorteile von R

- Methoden- und Anwendungsvielfalt (Finance, Marketing, HR, Psychologie,...)
- Neue Methoden der Datenanalyse werden häufig in R entwickelt (auch Big Data, KI, etc.)
- Frei und Offen; Kostenlos
- Schnittstellen zu sehr vielen Datenquellen / -banken (auch SocialMedia etc.)
- Unzählige Nutzer*innen weltweit in Unternehmen und Wissenschaft
- Möglichkeiten für Reporting, Apps, etc.
- Numerische Stabilität / Genauigkeit
- Große Entwickler*innen Gemeinde mit langer Geschichte (seit 1993);
  R Konsortium, u. a. IBM, Microsoft, Oracle, Google,...

© 2026 – Hochschule der Bayerischen Wirtschaft

Einführung in R
R und seine Gefährten

- **R** https://www.r-project.org/ ist das Basisprogramm.
- **RStudio Desktop** https://posit.co/products/open-source/rstudio/ ist eine komfortable Entwicklungsumgebung für R und bietet zusätzliche Tools, wie z. B. Dokumentenerstellung etc.
- **mosaic** https://cran.r-project.org/web/packages/mosaic/ ist ein Zusatzpaket, welches u. a. eine vereinheitlichte R Syntax bietet.

© 2026 – Hochschule der Bayerischen Wirtschaft

Zusammenarbeit
Statistik, R, RStudio und mosaic

- Das **Auto** (Statistik) sollten wir fahren können, um den Weg von der Forschungsfrage zur vorläufigen Antwort zu bringen.
- R, der **Motor**, treibt das Auto an und hilft uns dabei – um diesen müssen wir uns eigentlich nicht kümmern.
- Das **Cockpit**, (RStudio Desktop) steuert unseren Motor – das sollten wir bedienen können!
- Die **Zusatzausstattung** (Paket mosaic) ebenso, da es uns die Motorsteuerung vereinfacht und so schneller an unser erstes Ziel bringt.

R: der Motor

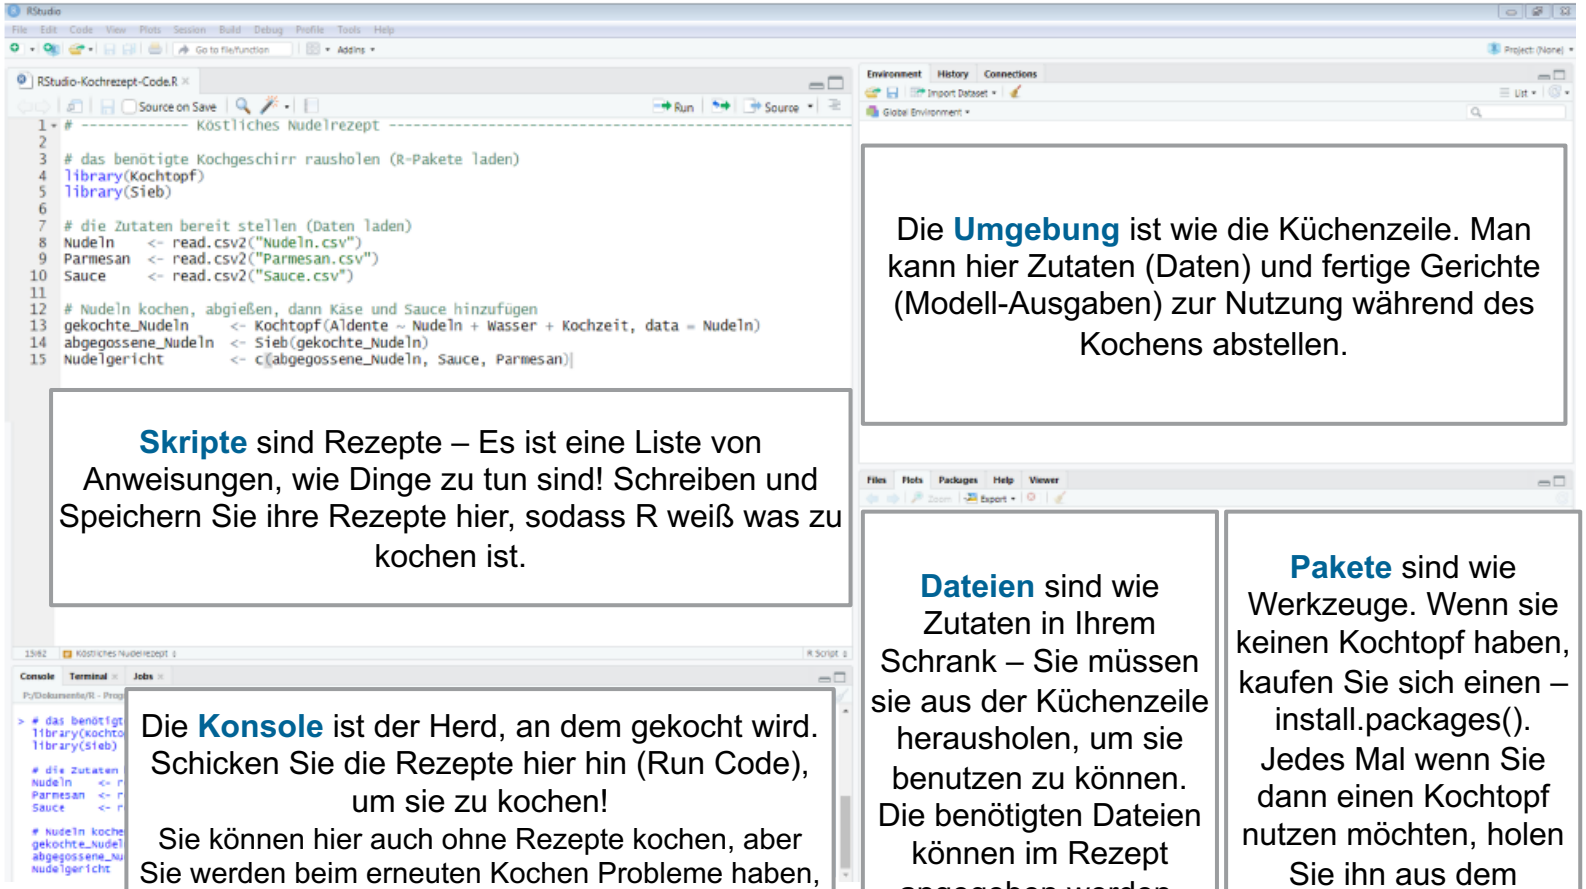


RStudio: das Cockpit



© 2026 – Hochschule der Bayerischen Wirtschaft

RStudio
Ansicht



Skripte sind Rezepte – Es ist eine Liste von Anweisungen, wie Dinge zu tun sind! Schreiben und Speichern Sie ihre Rezepte hier, sodass R weiß was zu kochen ist.

Die **Umgebung** ist wie die Küchenzeile. Man kann hier Zutaten (Daten) und fertige Gerichte (Modell-Ausgaben) zur Nutzung während des Kochens abstellen.

Die **Konsole** ist der Herd, an dem gekocht wird. Schicken Sie die Rezepte hier hin (Run Code), um sie zu kochen!

Sie können hier auch ohne Rezepte kochen, aber Sie werden beim erneuten Kochen Probleme haben, das Gericht nachzukochen, sodass es empfehlenswerter ist ein Rezept (Skript) zu nutzen.

Dateien sind wie Zutaten in Ihrem Schrank – Sie müssen sie aus der Küchenzeile herausholen, um sie benutzen zu können. Die benötigten Dateien können im Rezept angegeben werden.

Pakete sind wie Werkzeuge. Wenn sie keinen Kochtopf haben, kaufen Sie sich einen – install.packages(). Jedes Mal wenn Sie dann einen Kochtopf nutzen möchten, holen Sie ihn aus dem Schrank – library().

[1] Idee von und in Anlehnung an Jessica Ward https://twitter.com/RLadiesNCL/status/1138812826917724160, abgerufen am 14. März 2022

© 2026 – Hochschule der Bayerischen Wirtschaft

Pakete I
Pakete ermöglichen Zusatzfunktionen in R

- Pakete liefern einen erweiterten Funktions- und Befehlsumfang, um leichter (mosaic) mit R zu arbeiten oder um spezifische Analysen und Anwendungen bereit zu stellen (dplyr)
- Benötigt wird (erstmal) nur ein Paket: mosaic (in diesem sind viele Pakete integriert (z.B. dplyr, muss also nicht extra installiert und geladen werden)).
- Standard R Befehle können immer angewandt werden. Um spezifische Paketbefehle nutzen zu können müssen Pakete immer(!) geladen werden – Sind Pakete geladen oder aktiviert, so kann R auf die hinterlegten Befehle zugreifen.

© 2026 – Hochschule der Bayerischen Wirtschaft

Pakete II
Installieren

Pakete installieren

- Für die Veranstaltung werden wir u.a. das Zusatzpaket ("package") “mosaic" verwenden. Installieren Sie dieses, in dem Sie in der R-Console den Befehl

```
install.packages("mosaic", dependencies = TRUE)
```

  eingeben und jeweils `Enter` oder `Return` drücken. Sie brauchen dafür eine Internetverbindung. Es werden noch weitere, abhängige Zusatzpakete installiert, der Vorgang kann also evtl. eine Weile dauern.
- Die Installation von Zusatzpaketen muss nur einmal erfolgen.

© 2026 – Hochschule der Bayerischen Wirtschaft

Pakete III
Laden

Pakete laden (aktivieren)

- Die Verwendung der Zusatzpakete hingegen muss bei jeder Sitzung neu geladen/ gestartet werden. Dazu muss jedes Paket mit dem Befehl library() gestartet werden.

```
library(mosaic)
```

Die angegebenen Meldungen sind **nur Hinweise**, **keine Fehler**!

```
Registered S3 method overwritten by 'mosaic':
  method                           from
  fortify.SpatialPolygonsDataFrame ggplot2

The 'mosaic' package masks several functions from core packages in order to add
additional features.  The original behavior of these functions should not be affected by this.

Attache Paket: ‘mosaic’

Die folgenden Objekte sind maskiert von ‘package:dplyr’:

    count, do, tally

[…]
```


© 2026 – Hochschule der Bayerischen Wirtschaft

mosaic
Der Grundbefehl

- Mosaic wurde für Sie als R-Studenten entwickelt
- Es gibt einen einzigen (!) Code mit wenigen Variationen

```
Befehl_was_mag_ich_machen( abhVar ~ unabhVar | Bedingung, data = meineDaten)
```

- Eine Bedingung ermöglicht z.B. eine Gruppierung

```
analysiere(y ~ x | z, Optionen, data = meine_daten)
```

```
analysiere(y         # abhängige Variable
           ~ x       # unabhängige Variable(n)
           | z,      # ggf. bedingende (gruppierende) Variable(n)
           Optionen, # ggf. weitere Optionen
           data = meine_daten)  # Datensatz
```

Hinweis: unter macOS: ~: opt+n |: opt+7

© 2026 – Hochschule der Bayerischen Wirtschaft

Zentrale Fragen

1. Was soll der Computer für mich tun?
2. Was muss der Computer dafür wissen?

```
meine.analyse(mein.y ~ mein.x, data = meine.daten)
```


© 2026 – Hochschule der Bayerischen Wirtschaft

Grafiken

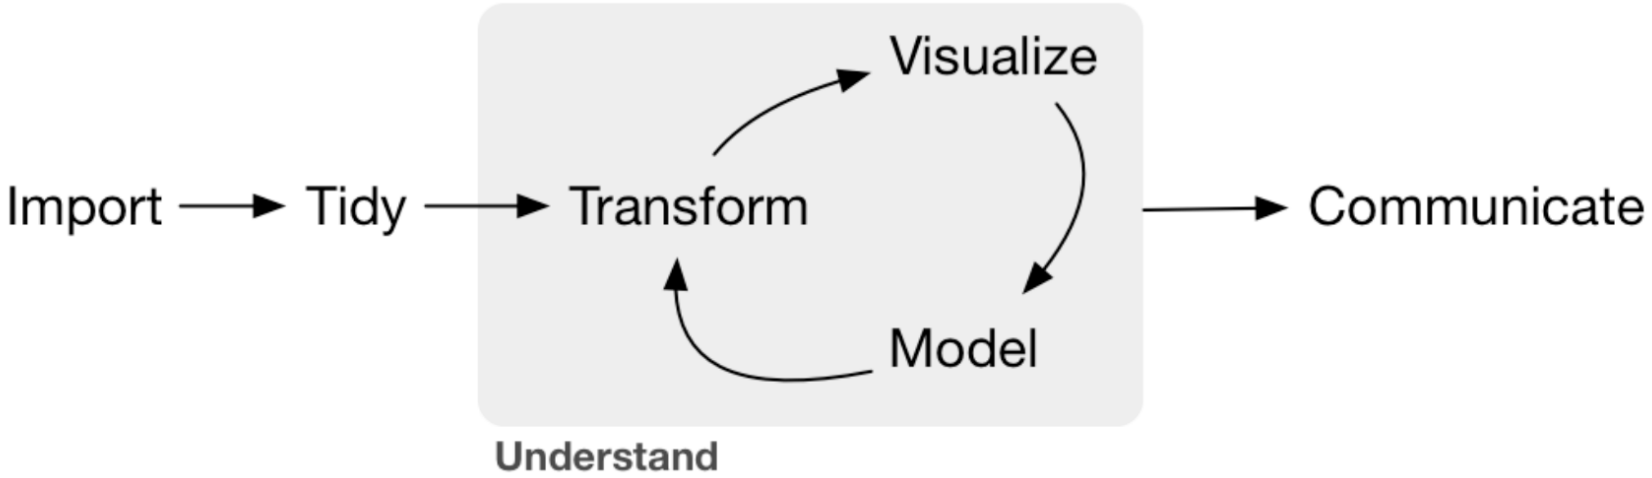
Bei Graphiken ist

- y = y-Achse (abhängige Variable)
- x = x-Achse (unabhängige Variable)
- z = Bedingungsvariable

y ~ x | z („ y wird modelliert von (oder hängt ab von) x | gruppiert nach den Stufen von z“)

© 2026 – Hochschule der Bayerischen Wirtschaft

Schritte der Datenanalyse
Überblick

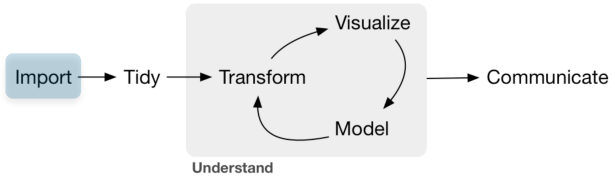


Quelle: Wickham / Grolemund (2018), S. ix

- Siehe hierzu und den nachfolgenden Folien auch https://r4ds.had.co.nz/introduction.html

© 2026 – Hochschule der Bayerischen Wirtschaft

Schritte der Datenanalyse
Import: Daten einlesen



Sind die Dateien z.B. im Verzeichnis

`C:/Ordner/weitere Unterordner/Vorlesung` abgespeichert

muss R wissen, wo sich die Dateien befinden.

Mit

```
setwd("/Users/ihrname/Ordner/Unterordner…/Vorlesung")      (Mac)
setwd("C:/Ordner/Unterordner…/Vorlesung")                  (Windows)
```

wird das Arbeitsverzeichnis festgelegt.
Wichtig: Der Pfad muss mit / (slash) geschrieben werden und in " " stehen!

Mit

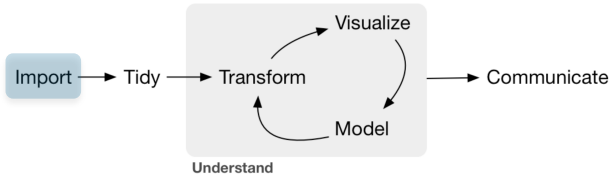
```
getwd()
```

können Sie sich das aktuelle Arbeitsverzeichnis anzeigen lassen, z.B.

```
[1] "/Users/christianschmitt/Desktop/10 HDBW/13 Financial Data Science/Work-R "
```


© 2026 – Hochschule der Bayerischen Wirtschaft

Schritte der Datenanalyse
Import: Daten einlesen



Einlesen von Dateien

```
data <- read.csv(„meineDatentabelle.csv“)
```

```
data <- read.csv2(„meineDatentabelle.csv“)
```

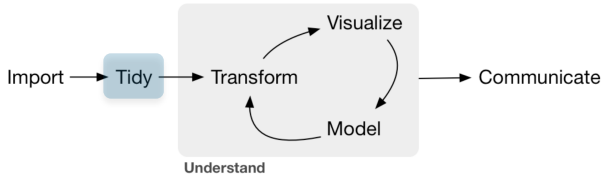
- Mit `data <-` wird der Inhalt der Datei der Tabelle `„data“` zugeordnet. Die Daten können nun aufgerufen, bearbeitet und analysiert werden.

WICHTIG:

- `read.csv()` liest Daten mit Dezimalpunkt ein (englische/amerikanischer Zahlenformat
- `read.csv2()` liest Daten mit Dezimalkomma ein (deutschsprachiges Zahlenformat)
- Lesen Sie ein Dezimalpunkt mit `read.csv2()` ein, so werden die Daten nicht richtig eingelesen und umgekehrt!

© 2026 – Hochschule der Bayerischen Wirtschaft

Schritte der Datenanalyse
Tidy: Daten bereinigen



tidy data bedeutet, dass Ihre Daten nach einer anerkannten, gebräuchlichen und einheitlichen Form auf- bzw. vorbereitet sind – der einheitlichen Form eines Datensatzes.

- *tidy* data bedeutet, dass jede Spalte eine Variable enthält und jede Zeile eine Beobachtung.
- Jede Spalte hat einen „Spalten-“ bzw. „Variablennamen“
- Jede Zeile gehört einer Beobachtung, welche meist durch Eine Art „ID“ zuordenbar ist.
- Entsprechen die Daten nicht dieser Form, so sollte die Datentabelle in diese Form gebracht werden!
- Sind die Daten *tidy*, so werden diese im nächsten Schritt transformiert.

Datensatz (Normalform)

Name	Geschlecht	Größe
Adalbert	M	180
Gabi	W	170
Max	M	**162**
Susi	W	174

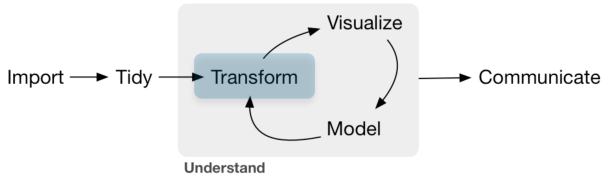
in Zeilen: Beobachtungen

in Spalten: Merkmal / Variable

Wert / Ausprägung

© 2026 – Hochschule der Bayerischen Wirtschaft

Schritte der Datenanalyse
Transform: Daten transformieren

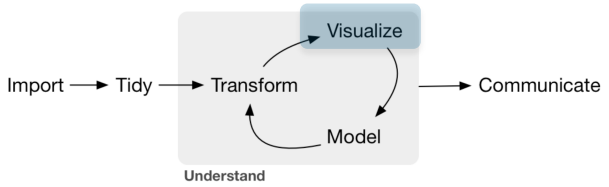


Ziel der Transformation ist es, die Variablen zu erzeugen/ zusammenzufassen o.ä., welche ggf. (zusätzlich) zur Analyse benötigt werden und notwendig sind.

- Einschränken auf die Daten, die von Interesse sind, z.B.
  - alle Beobachtungen einer Stadt
  - Aktienkurse in einem bestimmten Zeitraum
- Erzeugen neuer Variablen, z.B.
  - Tempoberechnung aus Distanz und Zeit
  - Renditen aus dem aktuellen Aktienkurs und dem der Vorperiode
- Berechnung von statistischen Parametern (Überblick), z.B.
  - Mittelwerte oder Anzahlen
  - Volatilitäten oder Korrelationen

© 2026 – Hochschule der Bayerischen Wirtschaft

Schritte der Datenanalyse
Visualize: Daten visualisieren

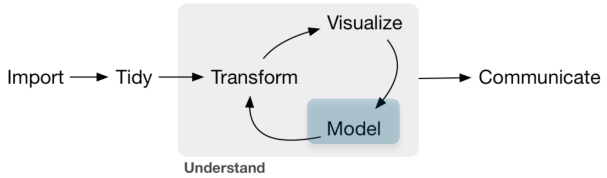


Die Visualisierung der Daten ermöglicht es ungeahnte Strukturen und Muster in den Daten „sichtbar“ zu machen.

- Ungeahnte Strukturen oder auffällige Muster in den Daten werfen neue Fragen hinsichtlich der Daten auf oder zeigen, dass ggf. weitere Daten notwendig sind.
- Der **Zyklus zwischen Visualisierung und Modellierung** kann sich einige Male wiederholen....

© 2026 – Hochschule der Bayerischen Wirtschaft

Schritte der Datenanalyse
Model: Daten modellieren



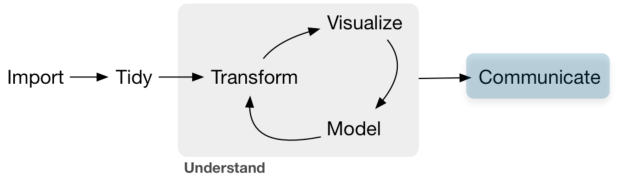
Die Modellierung der Daten ist die Ergänzung der Visualisierung der Daten

- Ist die Frage ausreichend präzise gestellt, so kann diese mittels Modellierung beantwortet werden.
- Modellierungen sind grundlegende mathematische oder rechnergestützte Möglichkeiten im Bereich der Datenanalyse
- Ein Modell ist somit ein Werkzeug zur Hypothesenprüfung, welche nach der Modellierung/Analyse angenommen oder verworfen wird.

© 2026 – Hochschule der Bayerischen Wirtschaft

Schritte der Datenanalyse

Communicate: Ergebnisse mitteilen / publizieren



Eine Kommunikation der Daten ist essentiell, auch wenn sich ein anderes Ergebnis (kein Ergebnis) einstellte, als mensch gedacht oder erhofft hatte.

- Die adäquate und zielgerichtete Publikation der Daten, kann nur dann erfolgen, wenn man seine Daten gut kennt und versteht !!

© 2026 – Hochschule der Bayerischen Wirtschaft

Einführung in R
Beispiel: Datensatz `Alcohol`

Ggf. einmalig vorab mosaic installieren:

```
install.packages("mosaic")
```

Paket mosaic in jeder Sitzung laden:

```
library(mosaic)
```

Internen Datensatz Alcohol laden:

```
data(Alcohol)
```

Datensatzbeschreibung (Hilfe zu den Daten):

```
?Alcohol
```

Daten betrachten:

```
View(Alcohol)
```


© 2026 – Hochschule der Bayerischen Wirtschaft

Einführung in R
Beispiel: Datensatz `Alcohol`

Daten betrachten:

```
View(Alcohol)
```



	country	year	alcohol
1	Russia	1985	13.31
2	Russia	1986	10.77
3	Russia	1987	10.96
4	Russia	1988	11.57
5	Russia	1989	12.04
6	Chile	1990	9.43
7	Ecuador	1990	8.40
8	Greece	1990	12.51
9	Russia	1990	12.29
10	Russia	1991	12.67
11	Macedonia [FYROM]	1992	12.66
12	Russia	1992	13.23
13	Moldova	1993	18.10
14	Russia	1993	13.60
15	Slovenia	1993	24.19

Showing 1 to 16 of 411 entries, 3 total columns

© 2026 – Hochschule der Bayerischen Wirtschaft

- Häufig müssen Daten vor der eigentlichen Analyse vorverarbeitet werden, z. B.:
  - Variablen auswählen: `select()`
  - Beobachtungen auswählen: `filter()`
  - Variablen verändern, neu erzeugen: `mutate()`
  - ...

[1] wird mit `mosaic` installiert und geladen. http://dplyr.tidyverse.org/index.html

© 2026 – Hochschule der Bayerischen Wirtschaft

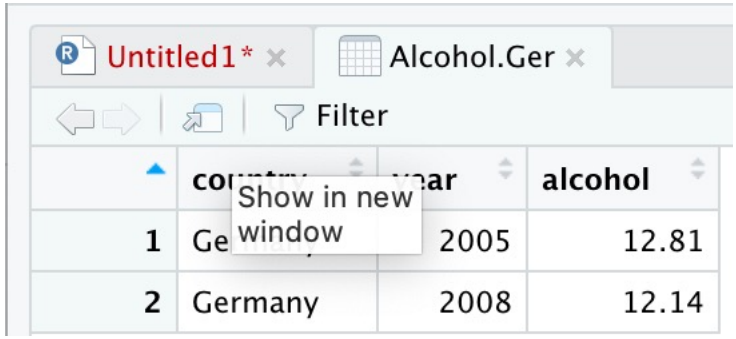
Einführung in R
`filter()` wählt Beobachtungen aus

`Alcohol.Ger` soll das Ergebnis sein von:

- Nimm den Datensatz `Alcohol` und dann...
- filtere auf die Beobachtungen, in denen das Land Deutschland ist.

```
Alcohol.Ger <- Alcohol %>%
filter(country == "Germany")
```

```
View(Alcohol.Ger)
```



© 2026 – Hochschule der Bayerischen Wirtschaft

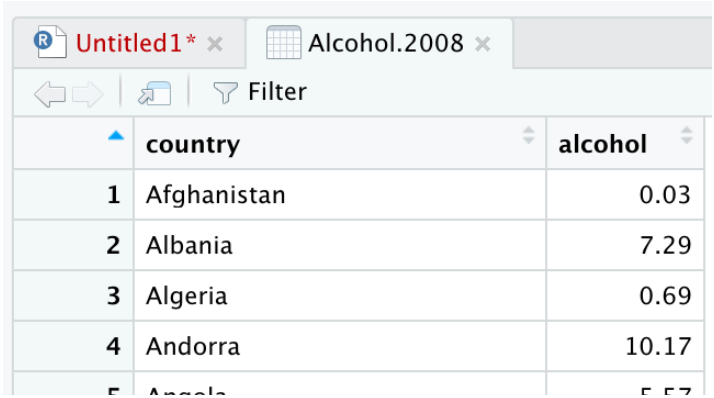
Einführung in R
`select()` wählt Variablen aus

`Alcohol.2008` soll das Ergebnis sein von:

- Nimm den Datensatz `Alcohol` und dann...
- filtere auf die Beobachtungen, in denen das Jahr 2008 ist und dann...
- selektiere die Variablen Land und Alkohol.

```
Alcohol.2008 <- Alcohol %>%
filter(year == 2008) %>%
select(country, alcohol)
```

```
View(Alcohol.2008)
```



	country	alcohol
1	Afghanistan	0.03
2	Albania	7.29
3	Algeria	0.69
4	Andorra	10.17

© 2026 – Hochschule der Bayerischen Wirtschaft

Einführung in R
`arrange()` sortiert Beobachtungen

`Alcohol.2008.sort` soll das Ergebnis sein von:

- Nimm den Datensatz `Alcohol.2008` und dann...
- sortiere nach der Variable Alkohol.

```
Alcohol.2008.sort <- Alcohol.2008 %>%
arrange(alcohol)
```

```
View(Alcohol.2008.sort)
```



	country	alcohol
1	Afghanistan	0.03
2	Pakistan	0.05
3	Kuwait	0.10
4	Libya	0.10
5	Mauritania	0.11
6	Bangladesh	0.17

© 2026 – Hochschule der Bayerischen Wirtschaft

Einführung in R
`mutate()` verändert bzw. erzeugt Variablen

`Alcohol.2008.rank` soll das Ergebnis sein von:

- Nimm den Datensatz `Alcohol.2008` und dann...
- erzeuge neue Variable rank als Rang der Beobachtung in der Variable Alkohol.

```
Alcohol.2008.rang <- Alcohol.2008 %>%
mutate(rang = rank(alcohol))
```

```
View(Alcohol.2008.rang)
```

Untitled1* | Alcohol.2008.rang

Filter

	country	alcohol	rang
1	Afghanistan	0.03	1.0
2	Albania	7.29	109.0
3	Algeria	0.69	20.0
4	Andorra	10.17	145.0
5	Angola	5.57	90.0
6	Antigua and Barbuda	8.17	118.0
7	Argentina	9.35	130.0

© 2026 – Hochschule der Bayerischen Wirtschaft

Einführung in R
Übung: Rangliste

```
Alcohol.2008.rang %>%
filter(country == "Germany")
```

```
  country alcohol rang
1 Germany   12.14  160
```

Ist Deutschland in der Stichprobe in dem Jahr das Land mit dem 160. in der Rangfolge geringsten oder höchsten Alkoholkonsum?

a. Geringsten.
b. Höchsten.

© 2026 – Hochschule der Bayerischen Wirtschaft

Einführung in R
Lösung Übung: Rangliste

```
Alcohol.2008.rang %>%
filter(country == "Germany")
```

```
  country alcohol rang
1 Germany   12.14  160
```

Ist Deutschland in der Stichprobe in dem Jahr das Land mit dem 160. in der Rangfolge geringsten oder höchsten Alkoholkonsum?

a. Geringsten.
b. Höchsten.

Die Ränge werden *aufsteigend* gebildet, d. h. **a.** Das Land mit Rang 1 hat dem geringsten Alkoholkonsum.

© 2026 – Hochschule der Bayerischen Wirtschaft

Einführung in R
Variablentypen in R

Struktur des Datensatzes `Alcohol`:

```
Alcohol.2008.rang %>%
filter(country == "Germany")
```

```
'data.frame':   411 obs. of  3 variables:
 $ country: chr  "Russia" "Russia" "Russia" "Russia" ...
 $ year   : int  1985 1986 1987 1988 1989 1990 1990 1990 1990 1991 ...
 $ alcohol: num  13.3 10.8 11 11.6 12 ...
```

- Ein Datensatz (`data.frame`) kann aus mehreren Variablen (Spalten) mit gleicher Anzahl Beobachtungen (Zeilen) bestehen. Für Variablen gibt es verschiedene Typen, u. a.:
- Zeichenketten (`character`) und Faktoren (`factor`)[1].
- Gleitkommazahlen (`numeric` bzw. `double`) und Ganze Zahlen (`integer`).

[1] Faktoren sind Zeichenketten, die eine definierte Menge an Werten (Ausprägungen, `levels`) annehmen können.

© 2026 – Hochschule der Bayerischen Wirtschaft

Einführung in R
Übung: Variablentyp

Als welcher Variablentyp sollten **kategorial-nominale Variablen** in R gespeichert werden?

a) `character` bzw. `factor`.
b) `integer`.
c) `numeric` bzw. `double`.

© 2026 – Hochschule der Bayerischen Wirtschaft

Einführung in R
Lösung Übung: Variablentyp

Als welcher Variablentyp sollten **kategorial-nominale Variablen** in R gespeichert werden?

a) `character` bzw. `factor`.
b) `integer`.
c) `numeric` bzw. `double`.

a) `integer` wird für ganze Zahlen, d. h. häufig numerisch diskrete und `numeric` für numerisch quasi-stetige Variablen verwendet.

© 2026 – Hochschule der Bayerischen Wirtschaft

Einführung in R
R im Studium

- Daten und deren Analyse sind **zentraler Bestandteil** wissenschaftlichen Arbeitens.
- Jede wissenschaftliche Arbeit sollte mind. eine Methode haben. In den zahlreichen Studiengängen sind dies häufig empirische Methoden – je nach Forschungsfrage qualitativ oder **quantitativ**.
- Zur Analyse von Daten sollte auf geeignete Software zurückgegriffen werden. Dabei ist die Software das Werkzeug, um die inhaltliche Arbeit (die Analyse) erledigen zu können.
- Es geht nicht primär darum, dass Sie R-Programmierung lernen, sondern dass Sie die **Daten (mit Hilfe von R) analysieren** können.

© 2026 – Hochschule der Bayerischen Wirtschaft

- R unterscheidet zwischen Groß- und Kleinbuchstaben
- R verwendet den Punkt `.` als Dezimaltrennzeichen
- Fehlende Werte werden in R durch `NA` kodiert
- Kommentare werden mit dem Rautezeichen `#` eingeleitet
- Eine Ergebniszuweisung erfolgt über `<-`
- `%>%` (Paket `dplyr` [1]) übergibt Ergebnisse. (Pipe-Operator)
- Hilfe zur Funktion `gf_bar:?gf_bar`

[1] wird von `mosaic` automatisch geladen

© 2026 – Hochschule der Bayerischen Wirtschaft

Einführung in R
Fehlermeldungen

- Die **häufigste Ursache von Fehlermeldungen** sind Tippfehler.
  - Genaues Lesen und googeln der Fehlermeldung helfen.
- Gerne vergisst man, die benötigten Pakete und Daten zu laden.
- R schreibt sowohl Hinweise, als auch Warnungen und Fehler `(Error)` in rot. Aber nur Fehler sind i. d. R. ein Problem, Hinweise nicht.
- Gibt R beim Laden eines Paketes `(library(XXX))` den Fehler aus, dass ein Paket fehlt `(Fehler in library(XXX): es gibt kein Paket namens 'XXX')`, so muss man das genannte Paket noch installieren `(install.packages("XXX"))`[1]
- Steht am Beginn einer Zeile in der Konsole ein `+`, so ist der vorherige Befehl noch nicht abgeschlossen.
- Reagiert R nicht, so kann es daran liegen, dass der aktuelle Befehl in der Konsole noch nicht abgeschlossen ist. → Ein einfacher Ausweg ist, in die Konsole zu klicken und dann die Escape-Taste (Esc) zu drücken. → Damit wird die aktuelle Befehlszeile in der Konsole abgebrochen.
- In RStudio kann über die Tabulatortaste (Tab) vervollständigt werden, über die Pfeiltasten können in der Konsole vorherige Befehle wiederholt werden.

[1] Am Besten gleich am Beginn einer R-Session.

© 2026 – Hochschule der Bayerischen Wirtschaft