

Kapitel 4
Explorative Datenanalyse

V26-10-25

© 2026 – Hochschule der Bayerischen Wirtschaft

Agenda

1. Einführung
2. Grundlagen quantitativer Datenanalyse
3. Einführung in R
4. **Explorative Datenanalyse**
5. Die Normalverteilung
6. Hypothesentests
7. Lineare Regression
8. Die Hausarbeit

© 2026 – Hochschule der Bayerischen Wirtschaft



Kapitel 4.1
Explorative Datenanalyse
Daten einlesen

V26-10-25

© 2026 – Hochschule der Bayerischen Wirtschaft

Einlesen der Tipping[1]-Daten (Trinkgeld-Datensatz):

```
# tips.csv ist aus Moodle heruntergeladen
# und im Arbeitsverzeichnis abgelegt
# Einlesen in R
tips <- read.csv2("tips.csv")

# Alternativ – heruntergeladene Datei einlesen
# und das Verzeichnis auswählen:
tips <- read.csv2(file.choose())
```

Tipp: Über den Befehl `getwd()` wird das aktuelle Verzeichnis ausgegeben, bzw. mit setwd(…) festgelegt.

[1] Bryant, P. G. and Smith, M (1995) Practical Data Analysis: Case Studies in Business Statistics. Homewood, IL: Richard D. Irwin Publishing

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Die csv-Datei

Dateiaufbau `tips.csv`[1]:

- Erste Zeile: Variablennamen[2]
- Datenfeldtrennzeichen der Variablen: ; (Semikolon)[3]
- Dezimaltrennzeichen: , (Komma)
- Textkennzeichen: " (Anführungszeichen)

```
"total_bill";"tip";"sex";"smoker";"day";"time";"size"
16,99;1,01;"Female";"No";"Sun";"Dinner";2
10,34;1,66;"Male";"No";"Sun";"Dinner";3
21,01;3,5;"Male";"No";"Sun";"Dinner";3
23,68;3,31;"Male";"No";"Sun";"Dinner";2
...
```

- *Hinweis*: Der Einlesebefehl in R hängt vom Dateiformat der Datei ab. Siehe z. B. `?read.table` oder Paket `readr` und `readxl`.

[1] Eine solche `csv`-Datei kann z. B. durch Export aus Tabellenkalkulationsprogrammen erzeugt werden.

[2] Tipp: Mit Buchstaben beginnen, keine Leer- oder Sonderzeichen verwenden, Umlaute vermeiden.

[3] In amerikanischen csv-Dateien ist das Datenfeldtrennzeichen das Komma (daher der Name: `csv` – Comma Separated Values) und das Dezimaltrennzeichen der Punkt. Solche Dateien können mit mit `read.csv()` eingelesen werden.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Variablen Trinkgeld-Datensatz

Ein Kellner sammelte über mehrere Monate Daten über sein Trinkgeld:

- `total_bill:` Rechnungshöhe in Dollar
- `tip:` Trinkgeld in Dollar
- `sex:` Geschlecht des Rechnungszahlenden
- `smoker:` Gab es Raucher*innen am Tisch?
- `day:` Wochentag
- `time:` Tageszeit / Mahlzeit
- `size:` Anzahl Personen am Tisch

```
str(tips) # gibt Informationen zur Struktur des Datensatzes
```

```
'data.frame':  244 obs. of  7 variables:
 $ total_bill: num  17 10.3 21 23.7 24.6 ...
 $ tip       : num  1.01 1.66 3.5 3.31 3.61 4.71 2 3.12 1.96 3.23 ...
 $ sex       : chr  "Female" "Male" "Male" "Male" ...
 $ smoker    : chr  "No" "No" "No" "No" ...
 $ day       : chr  "Sun" "Sun" "Sun" "Sun" ...
 $ time      : chr  "Dinner" "Dinner" "Dinner" "Dinner" ...
 $ size      : int  2 3 3 2 4 4 2 4 2 2 ...
```


© 2026 – Hochschule der Bayerischen Wirtschaft

Zur Erinnerung

```
# Ggf. Einmalig vorab installieren
install.packages("mosaic")

# Pakete müssen bei jedem Start von R bzw. RStudio geladen werden
# Paket mosaic laden
library(mosaic)
```


© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Aufbau Datensatz

Wie viele kategoriale Variablen liegen vor?

a) 1
b) 2
c) 4
d) 7
e) 244

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: Aufbau Datensatz

Wie viele kategoriale Variablen liegen vor?

a) 1
b) 2
c) 4
d) 7
e) 244

Es liegen **4 (Antwort c))** kategoriale Variablen vor (`sex`, `smoker`, `day`, `time`), als Factor gespeichert. Die anderen sind metrische Variablen, 1 davon diskret (`size - integer`), 2 stetig (`total_bill`, `tip - numeric`).

7 ist die Gesamtzahl an Variablen und 244 ist die Anzahl der Beobachtungen.

© 2026 – Hochschule der Bayerischen Wirtschaft







Kapitel 4.2
Explorative Datenanalyse
Analyse kategorialer Daten

V26-10-25

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Variablen Trinkgeld-Datensatz

Ein Kellner sammelte über mehrere Monate Daten über sein Trinkgeld:

- `total_bill:` Rechnungshöhe in Dollar
- `tip:` Trinkgeld in Dollar
- `sex:` Geschlecht des Rechnungszahlenden
- `smoker:` Gab es Raucher*innen am Tisch?
- `day:` Wochentag
- `time:` Tageszeit / Mahlzeit
- `size:` Anzahl Personen am Tisch

Welche Fragen fallen Ihnen ein, bzw. was würden Sie gerne wissen, wenn Sie die o.g. Variablen lesen?



„Exploratory data analysis is detective work“
(Tukey, 1977, Begründer der explorativen Datenanalyse)

Quelle: https://alchetron.com/John-Tukey

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse

Graphiken

- ***Säulendiagramm / Balkendiagramm:*** Häufigkeit von Merkmalsausprägungen (nominal, ordinal, metrisch diskret), vertikale Ausrichtung.
    - Vertikale Ausrichtung: Säulendiagramm
    - Horizontale Ausrichtung: Balkendiagramm
- ***Mosaikplot****:* Darstellung der Merkmalsausprägungen zweier nominaler Merkmale.
- ~~***Kreisdiagramm***~~ [1]

Häufigkeiten

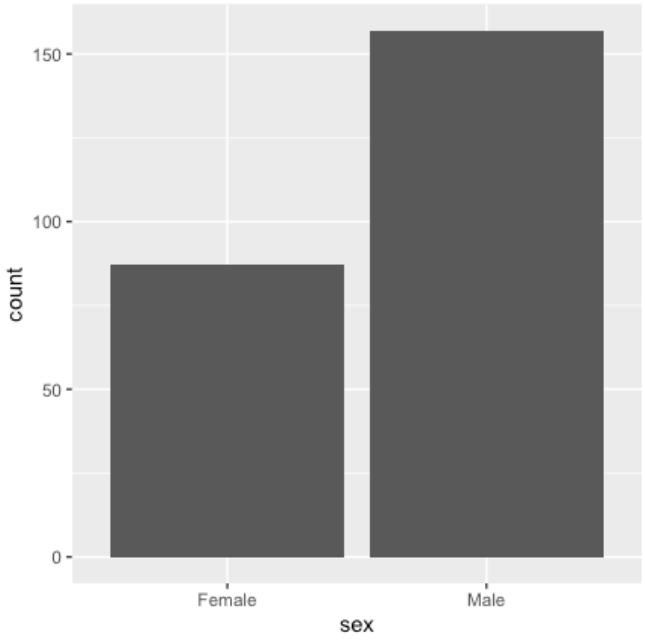
- ***Anteile****:* Relative Anteile der verschiedenen Merkmalsausprägungen kategorialer Merkmale (nominal, ordinal).
- ***Kreuztabelle:*** Tabelle der verschiedenen Merkmalsausprägungen kategorialer Merkmale (nominal, ordinal), entweder in absoluten oder relativen Häufigkeiten.

[1] Siehe z. B. Regel 20 von https://robjhyndman.com/hyndsight/graphics/ , abgerufen am 04. März 2022

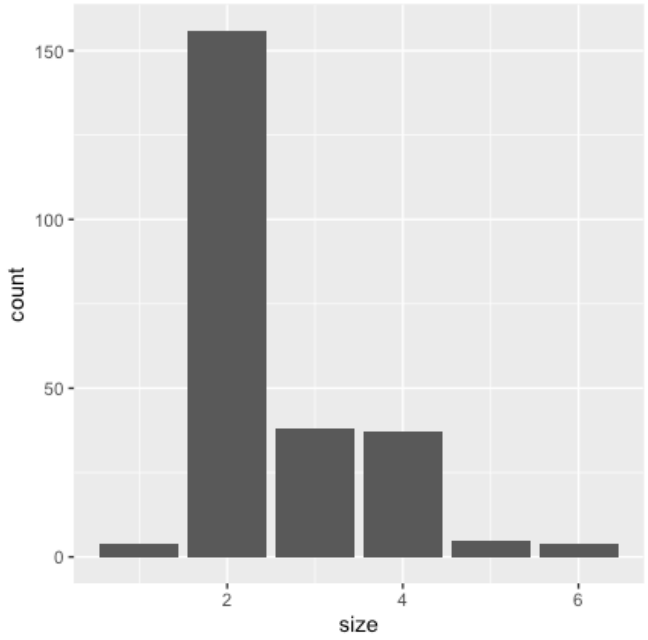
© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Säulendiagramm[1]

Visualisiert die absoluten oder relativen Häufigkeiten von Beobachtungen von kategorialen (oder metrisch diskreten) Variablen durch die Höhe der Säulen.



Kategoriale Variable: sex



Metrisch diskrete Variable: size

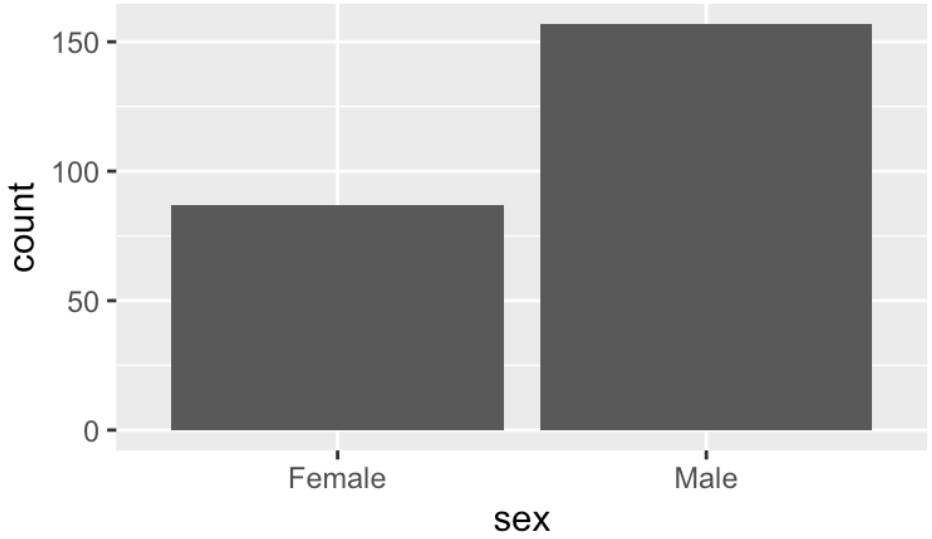
[1] Wird häufig auch als Balkendiagramm bezeichnet, korrekterweise hat ein Balkendiagramm aber querliegende Balken.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Analyse: Geschlecht RechnungszahlerIn

Analysiere über Säulendiagramm

```
gf_bar( ~ sex, # (unabhängige) Variable, die analysiert wird
     data = tips) # Datensatz
```



Welche Aussage stimmt?

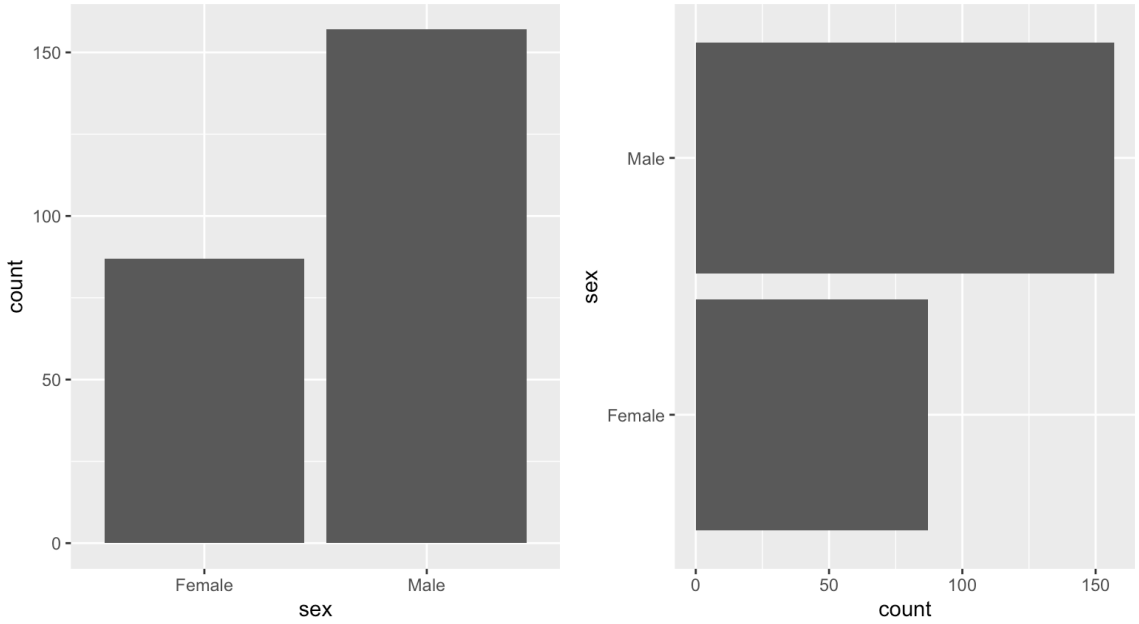
a) Bei einer Mehrheit der Stichprobe zahlt eine Frau.
b) Bei einer Mehrheit der Stichprobe zahlt ein Mann.
c) Weiß nicht.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Analyse: Geschlecht RechnungszahlerIn

Analysiere über Säulendiagramm oder Balkendiagramm:

```
# Zwei Plots erzeugen
plot1 <- gf_bar( ~ sex, # (unabhängige) Variable, die analysiert wird
                 data = tips) # Datensatz
plot2 <- gf_barh( ~ sex, data = tips)
# Nebeneinander anzeigen
grid.arrange(plot1, plot2, nrow = 1)
```



© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Anteil Frauen

Analysiere über Anteil p:

```
prop( ~ sex, # (unabhängige) Variable die analysiert wird
     success = "Female", # wovon den Anteil bestimmen
     data = tips) # Datensatz
```

```
prop_Female
  0.3565574
```


© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Tabellierung

Analysiere über Tabellen:

Absolute Häufigkeit h_i:

```
tally( ~ sex, # Variable die analysiert wird
     data = tips) # Datensatz
```

```
sex
Female   Male
    87    157
```

Relative Häufigkeit $f_i = \frac{h_i}{n}$ (Option format = "proportion"):

```
tally( ~ sex, # Variable die analysiert wird
     format = "proportion", # Option: Anteile
     data = tips) # Datensatz
```

```
sex
   Female      Male
0.3565574 0.6434426
```


© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Modellierung Geschlecht

Das Geschlecht des Rechnungszahlenden (sex) **variiert:**
Mal zahlt ein Mann, mal zahlt eine Frau.

Welche der anderen Variablen könnte einen Teil dieser Variation **modellieren**, d. h., womit könnte dies zusammenhängen?

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: Modellierung Geschlecht

Das Geschlecht des Rechnungszahlenden (sex) **variiert:**
Mal zahlt ein Mann, mal zahlt eine Frau.

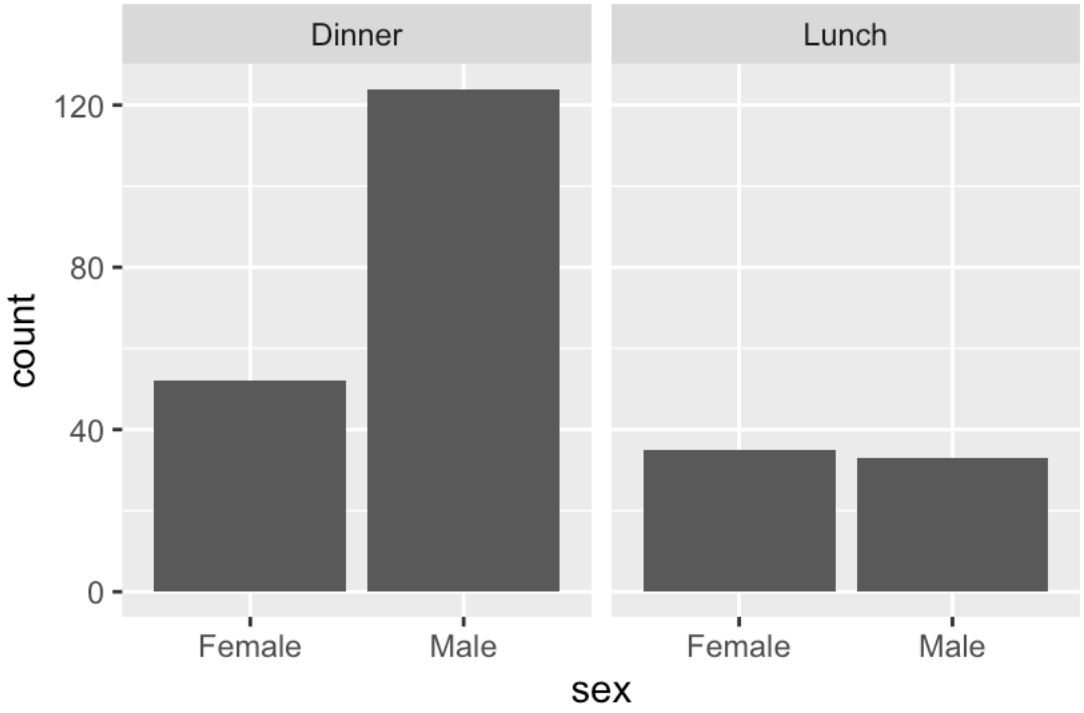
Welche der anderen Variablen könnte einen Teil dieser Variation **modellieren**, d. h., womit könnte dies zusammenhängen?

Hier ist vieles möglich – im folgenden versuchen wir es mit der **Tageszeit**
`time` → Geschlecht des Rechnungszahlenden je Tageszeit.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Gruppiertes Säulendiagramm

```
gf_bar( ~ sex     # Variable die analysiert wird
      | time,     # Variable nach der bedingt wird
      data = tips)   # Datensatz
```



© 2026 – Hochschule der Bayerischen Wirtschaft

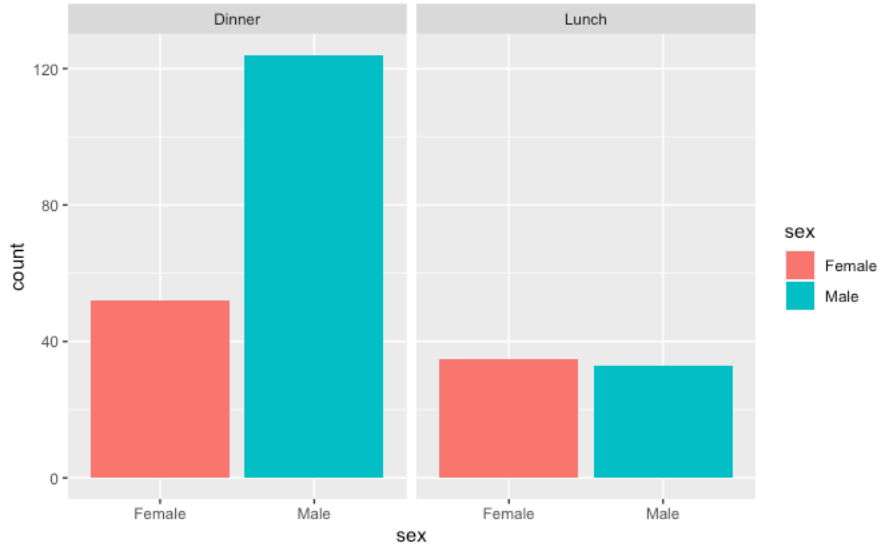
Explorative Datenanalyse

Gruppiertes Säulendiagramm mit Farben

EXKURS

Darstellung mit farblicher Kategorisierung in `gf_bar()` über die Option `fill`

```
gf_bar( ~ sex     # Variable die analysiert wird
      | time,     # Variable nach der bedingt wird
      fill = ~sex,   # unterschiedliche Farben für Variable
      data = tips)   # Datensatz
```



© 2026 – Hochschule der Bayerischen Wirtschaft

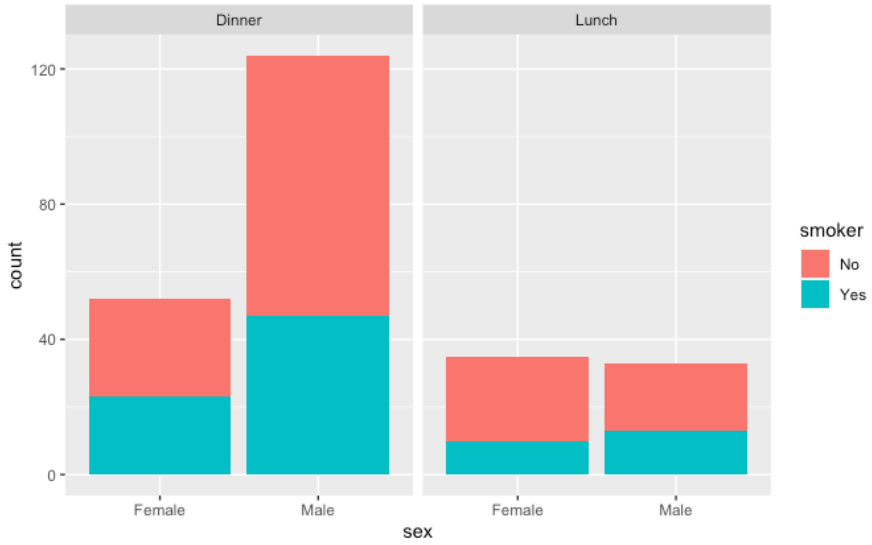
Explorative Datenanalyse

Gruppiertes Säulendiagramm mit Farben

EXKURS

Die Farbgebung kann sich auf eine weitere Variable beziehen: hier Raucherstatus

```
gf_bar( ~ sex     # Variable die analysiert wird
      | time,     # Variable nach der bedingt wird
      fill = ~smoker,   # unterschiedliche Farben für Variable
      data = tips)   # Datensatz
```

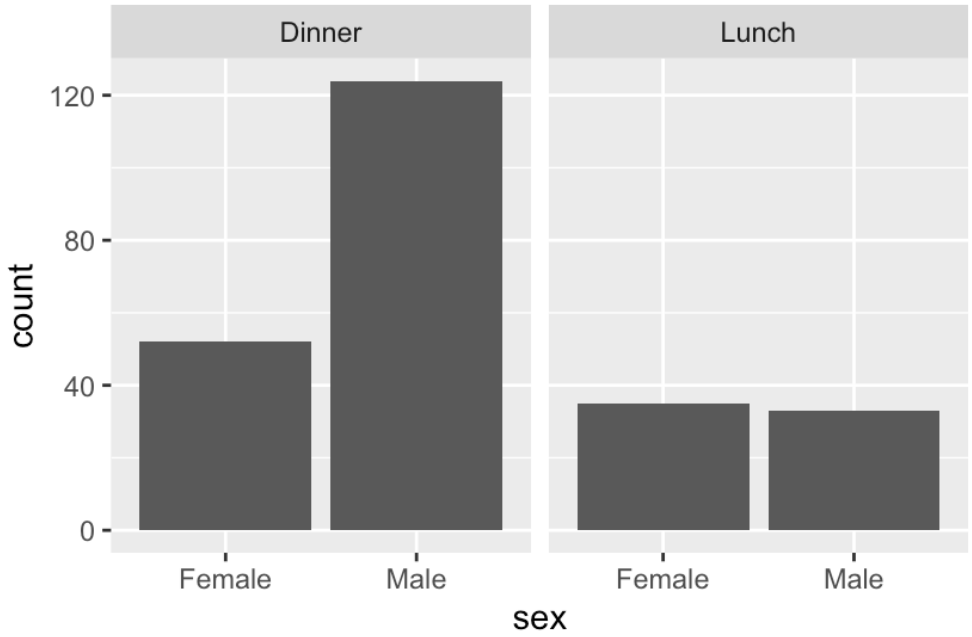


© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Geschlecht nach Tageszeit

Welche Aussage stimmt?

a) Beim Lunch zahlen mehr Frauen als Männer.
b) Beim Lunch zahlen weniger Frauen als Männer.
c) Beim Lunch zahlen gleich viele Frauen wie Männer.

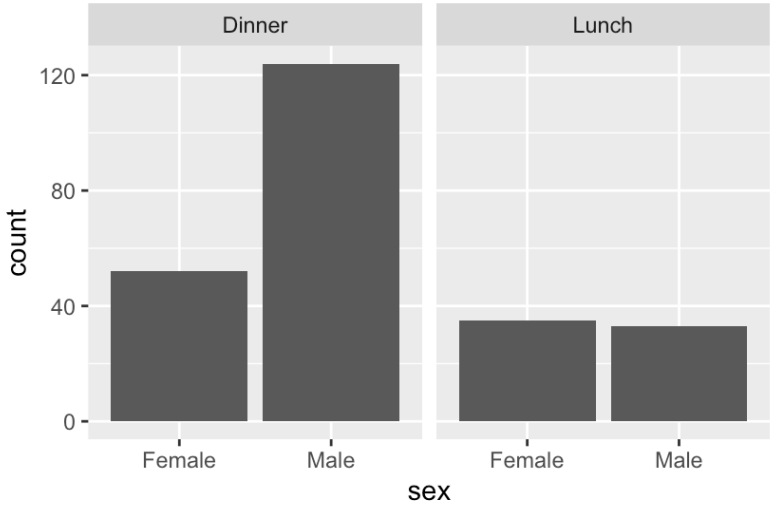


© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: Geschlecht nach Tageszeit

Welche Aussage stimmt?

a) Beim Lunch zahlen mehr Frauen als Männer.
b) Beim Lunch zahlen weniger Frauen als Männer.
c) Beim Lunch zahlen gleich viele Frauen wie Männer.



Antwort **a)** ist korrekt, im Bereich `Lunch` ist der Balken für `Female` etwas höher als der für `Male`. Aber man sieht auch, dass der Unterschied klein ist. In der nachfolgenden Kreuztabellierung sehen Sie dies auch in absoluten Zahlen und Anteilen ausgedrückt.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Kreuztabellierung Geschlecht nach Tageszeit

Absolute Häufigkeit je Mahlzeit:

```
tally( ~ sex   # Variable, die analysiert wird
     | time,   # Variable, nach der bedingt wird
     data = tips)  # Datensatz
```

```
        time
sex      Dinner Lunch
  Female     52    35
  Male      124    33
```

Relative Häufigkeit je Mahlzeit:

```
tally( ~ sex   # Variable, die analysiert wird
     | time,   # Variable, nach der bedingt wird
     format = "proportion", # Option: Anteile
     data = tips)  # Datensatz
```

```
        time
sex        Dinner     Lunch
  Female 0.2954545 0.5147059
  Male   0.7045455 0.4852941
```


© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Raucher je Wochentag

Welcher Befehl führt eine Kreuztabellierung der Anteile der Raucher je Wochentag durch?

a) `tally( ~ smoker | day, format = 'proportion', data = tips)`

b) `tally( ~ day | smoker, format = 'proportion', data = tips)`

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: Raucher je Wochentag

Welcher Befehl führt eine Kreuztabellierung der Anteile der Raucher je Wochentag durch?

a) `tally( ~ smoker | day, format = "proportion", data = tips)`
b) `tally( ~ day | smoker, format = "proportion", data = tips)`

a) ist die korrekte Antwort.

In dieser Reihenfolge werden zeilenweise die Ausprägungen von `smoker` dargestellt und spaltenweise die Ausprägungen von `day`, grundsätzliche Formeleingabe $y \sim x \mid z$, hier `smoker` gruppiert nach `day`.
Mit `format = "proportion"` werden die Anteile der Ausprägungen bezogen auf die jeweilige Spalte berechnet.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Kreuztabellierung Raucher und Wochentag

```
tally( ~ smoker | day, format = "proportion", data = tips)
```

```
      day
smoker       Fri       Sat       Sun      Thur
   No  0.2105263 0.5172414 0.7500000 0.7258065
   Yes 0.7894737 0.4827586 0.2500000 0.2741935
```

```
tally( ~ day | smoker, format = "proportion", data = tips)
```

```
      smoker
day            No        Yes
  Fri  0.02649007 0.16129032
  Sat  0.29801325 0.45161290
  Sun  0.37748344 0.20430108
  Thur 0.29801325 0.18279570
```


© 2026 – Hochschule der Bayerischen Wirtschaft

Achtung: (Confusion of the inverse):

Wovon wird die relative Häufigkeit angegeben?

- Der relative Anteil der Raucher am Freitag entspricht nicht dem relativen Anteil des Freitags der Raucher.
- Der Papst ist ein Mann, aber nur die allerwenigsten Männer sind Papst.
- Die Wahrscheinlichkeit, **krank** zu sein, wenn das **Testergebnis positiv** ist, ist nicht dasselbe wie die Wahrscheinlichkeit, dass das **Testergebnis positiv** ist, wenn man **krank** ist.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: R Fehler

Was ist an diesem Befehl falsch?

```
tally( ~ x data = daten)
```

a) Es fehlt eine Option.
b) Es fehlt eine bedingende Variable.
c) Es fehlt ein Komma.
d) Gar nichts.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: R Fehler

Was ist an diesem Befehl falsch?

```
tally( ~ x data = daten)
```

a) Es fehlt eine Option.
b) Es fehlt eine bedingende Variable.
c) Es fehlt ein Komma.
d) Gar nichts.

Antwort **c)** ist korrekt, es fehlt ein Komma.
Korrekt ist:

```
tally( ~ x, data = daten)
```


© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: R Fehler

Was ist an diesem Befehl falsch?

```
Tally( ~ x, data = daten)
```


© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: R Fehler

Was ist an diesem Befehl falsch?

```
Tally( ~ x, data = daten)
```

R unterscheidet zwischen Groß- und Kleinschreibung, Tally gibt es nicht.

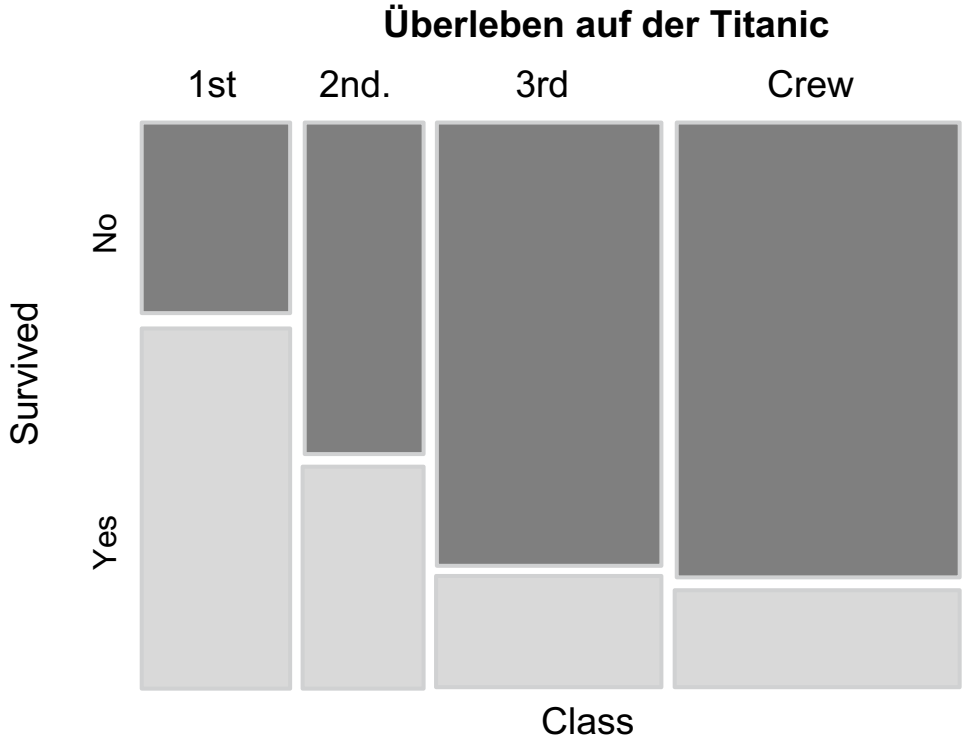
Korrekt muss es heißen:

```
tally( ~ x, data = daten)
```


© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Mosaikplot

Visualisiert die gemeinsame Verteilung von zwei kategorialen Variablen. Dabei entspricht die Höhe und Breite der Rechtecke der jeweiligen relativen Häufigkeit.



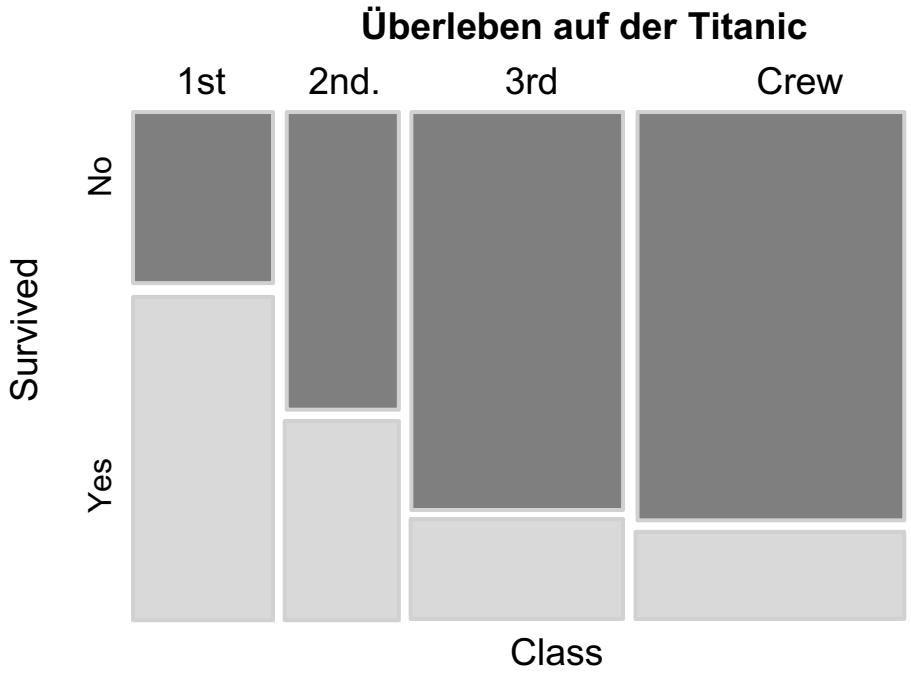
© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Mosaikplot

Stimmt die Aussage: Der Anteil der Überlebenden ist in der 1. Klasse größer als in den unteren Klassen?

a) Ja.

b) Nein.



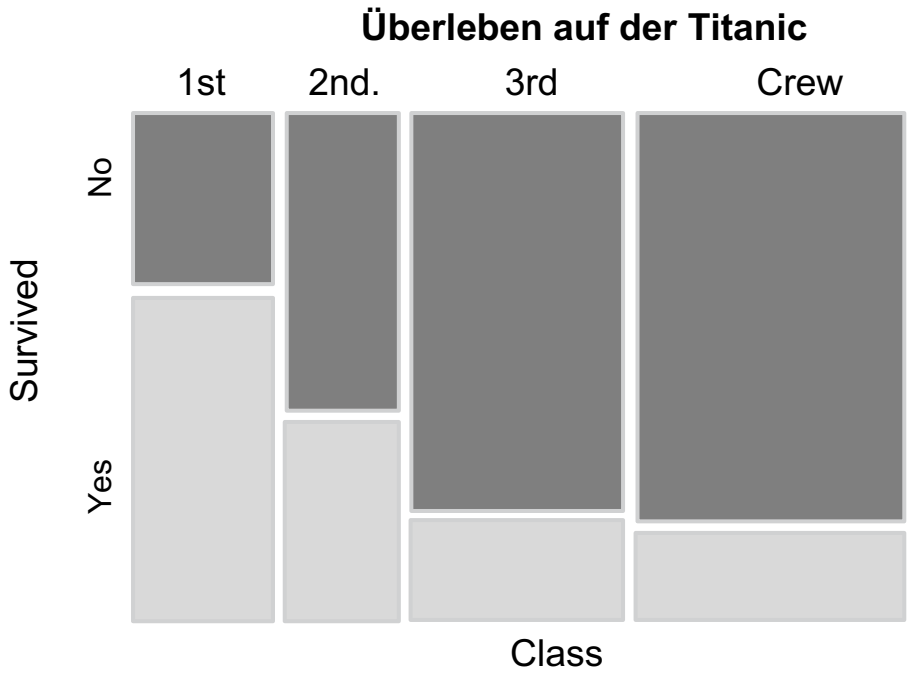
© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: Mosaikplot

Stimmt die Aussage: Der Anteil der Überlebenden ist in der 1. Klasse größer als in den unteren Klassen?

a) Ja.

b) Nein.



a) Ja,

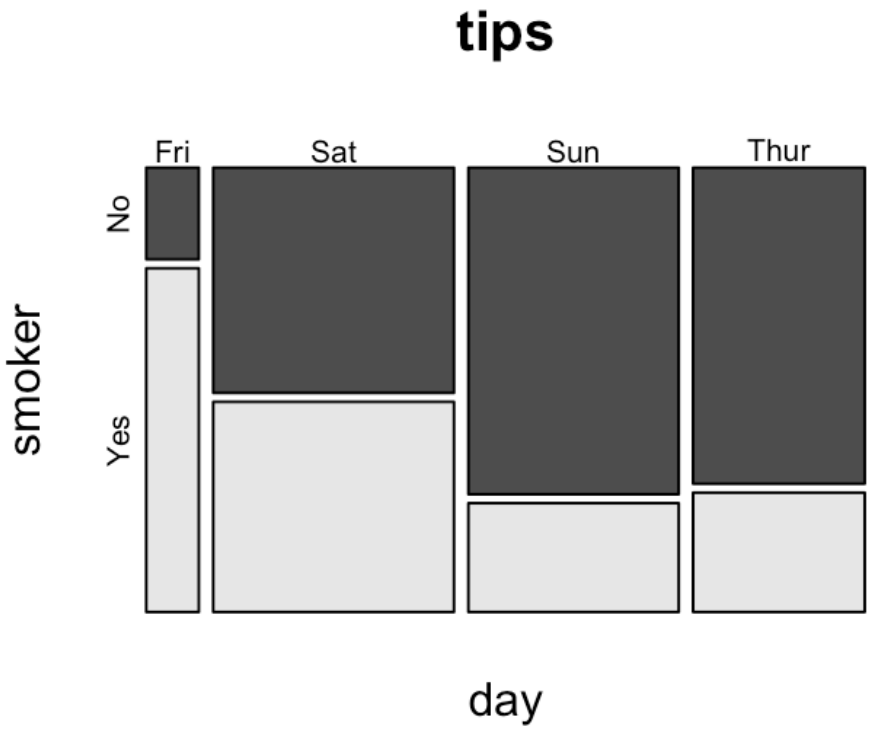
… da der Flächenanteil für `Yes` relativ größer ist als in den anderen Klassen.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Mosaikplot Raucher und Tage

So können Sie einen solchen Plot erzeugen.[1]

```
mosaicplot(day ~ smoker, data = tips, color = TRUE)
```



[1]Hinweis: Bei `mosaicplot()` sollten in der Formel die Achsen vertauscht werden, also x ~ y.

© 2026 – Hochschule der Bayerischen Wirtschaft

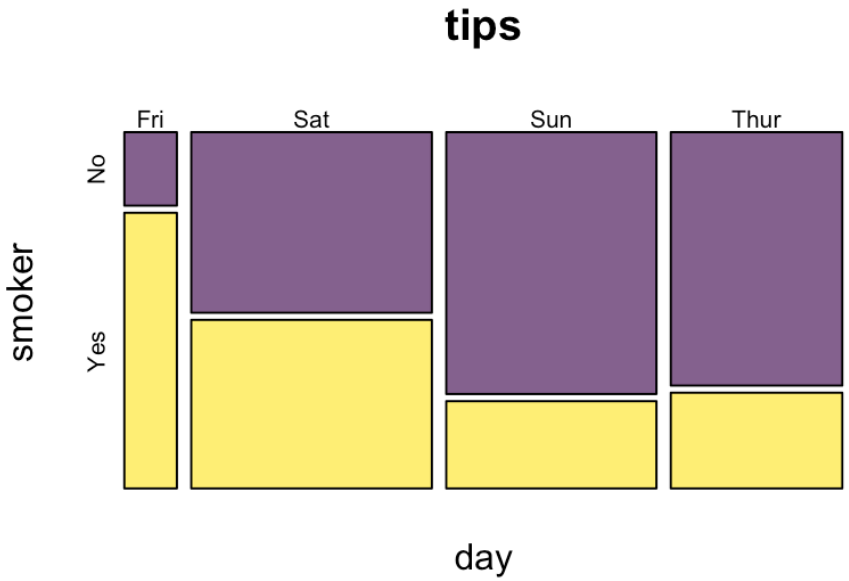
Explorative Datenanalyse
Farben

EXKURS

Wenn Sie Farbe ins Spiel bringen wollen: Installieren und laden sie einfach das Paket viridis.

```
install.packages("viridis")
library(viridis)

mosaicplot(day ~ smoker, data = tips, color = viridis(2, alpha = 0.7))
```



© 2026 – Hochschule der Bayerischen Wirtschaft







Kapitel 4.3

Explorative Datenanalyse

Analyse numerischer (metrischer) Daten

V26-10-25

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übersicht

Graphiken

- **Säulendiagramm / Balkendiagramm:** Häufigkeiten von Merkmalsausprägungen (nominal, ordinal, metrisch diskret).
- **Dotplot:** Häufigkeiten von Merkmalsausprägungen (nominal, ordinal, metrisch).
- **Histogramm:** Häufigkeit von gruppierten Merkmalsausprägungen (metrisch).
- **Boxplot:** Visualisierung von Median, oberem und unterem Quartil [1], Minimum und Maximum, Ausreißern (metrisch).
- **Streudiagramm / Scatterplot:** Darstellung der Merkmalsausprägungen von zwei i. d. R. metrischen Merkmalen [2] als Punkte.
- **Liniendiagramm:** Verlauf der Merkmalsausprägung eines Merkmals.

Kennzahlen

- **Lagemaß:** Beschreibt u. a. die zentrale Tendenz einer Verteilung.
- **Streumaß:** Beschreibt die Verteilung der Daten (häufig um das Lagemaß).
- **Schiefe:** Beschreibt die Form der Verteilung.

[1] Lagemaße: → Erläuterung folgt.

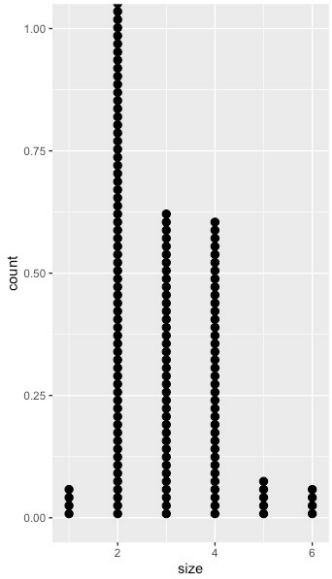
[2] Bei kategorialen oder metrisch diskreten Merkmalen ggfs. verwackeln (engl.: jitter) → Erläuterung folgt.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Dotplot

Ein **Dotplot** zeigt die Häufigkeiten der einzelnen Ausprägungen an.

```
gf_dotplot( ~ size, data = tips)
```



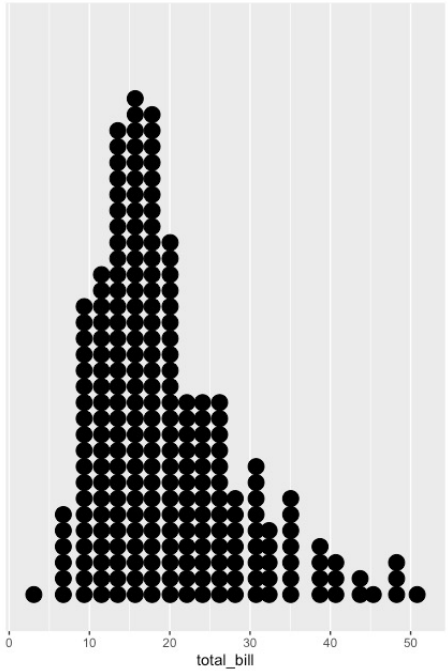
Hinweis: Die Skalierung an der y-Achse ist nicht sinnvoll. Sie können sie verbergen mit `gf_dotplot( ~ size, data = tips) %>% gf_theme(scale_y_continuous(NULL, breaks = NULL))`.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Dotplot

Der **Dotplot** kann auch für stetige Merkmale genutzt werden. Dann werden Bereiche in Intervalle (Klassen) zusammengefasst. Die Breite können Sie mit `binwidth =` festlegen.

```
gf_dotplot( ~ total_bill, data = tips, binwidth = 2) %>%
gf_theme(scale_y_continuous(NULL, breaks = NULL))
```

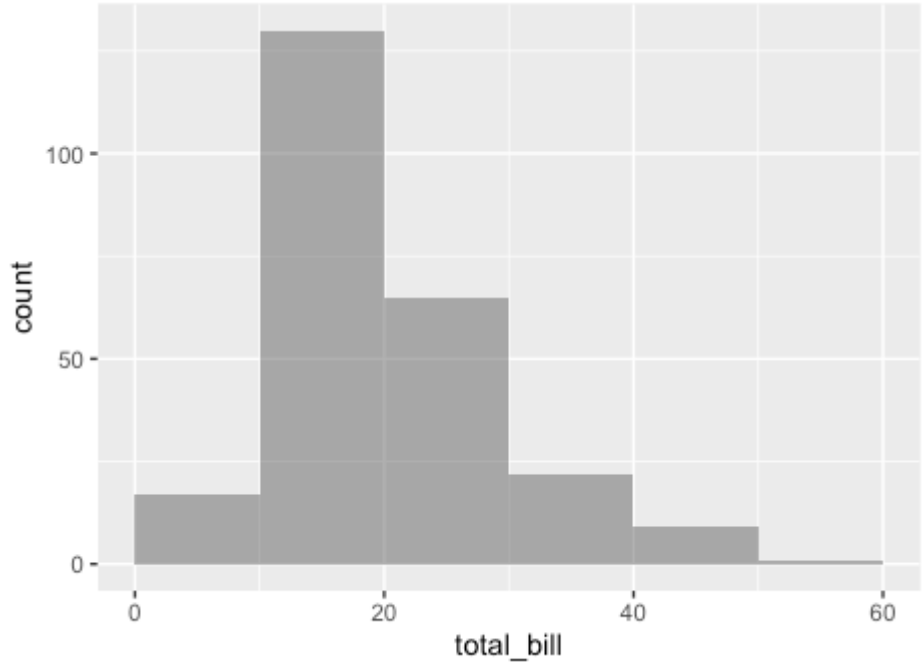


© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Histogramm

Ein **Histogramm** visualisiert die gruppierte Verteilung einer numerischen Variable. Der Flächeninhalt der Rechtecke entspricht dabei der relativen Häufigkeiten der Beobachtungen im Intervall (Klasse).

```
gf_histogram( ~ total_bill, data = tips, binwidth = 10, center = 5)
```

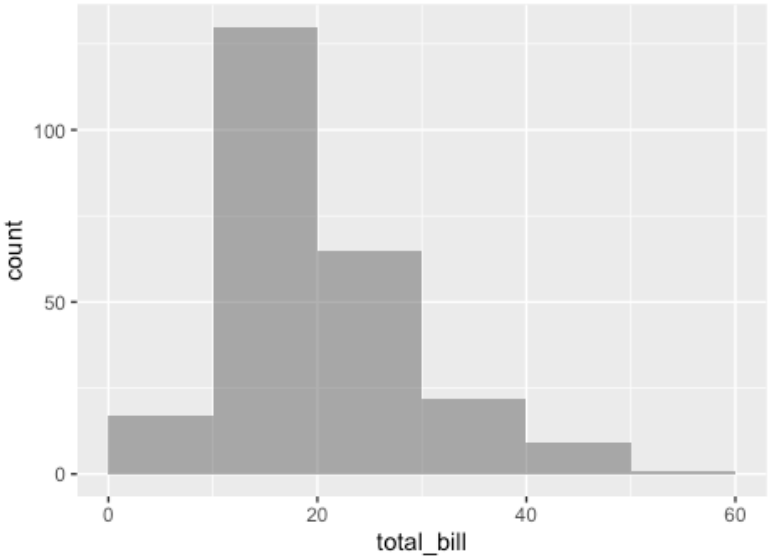


© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Histogramm

Welche Aussage stimmt?

a) Die meisten Werte sind ≤ 10.
b) Die meisten Werte sind > 10 und ≤ 20.
c) Die meisten Werte sind > 20 und ≤ 30
d) Die meisten Werte sind > 30 und ≤ 40
e) Die meisten Werte sind > 40 und ≤ 50
f) Die meisten Werte sind > 50.

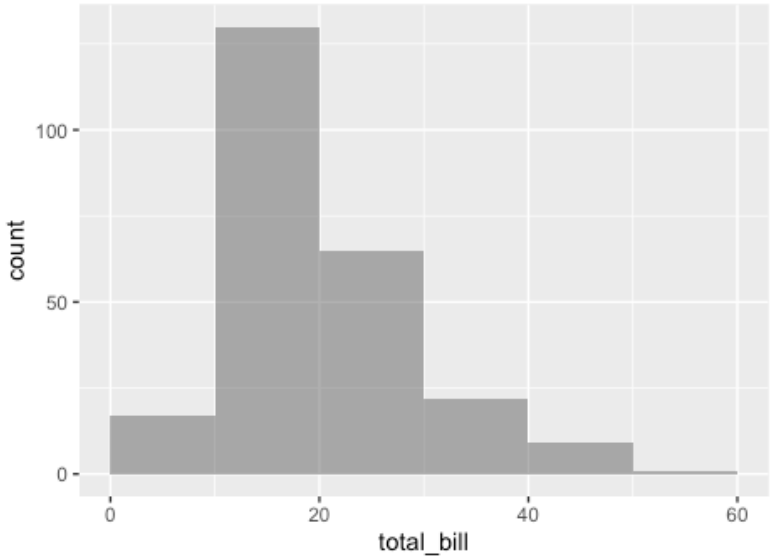


© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: Histogramm

Welche Aussage stimmt?

a) Die meisten Werte sind ≤ 10.
b) Die meisten Werte sind > 10 und ≤ 20.
c) Die meisten Werte sind > 20 und ≤ 30
d) Die meisten Werte sind > 30 und ≤ 40
e) Die meisten Werte sind > 40 und ≤ 50
f) Die meisten Werte sind > 50.

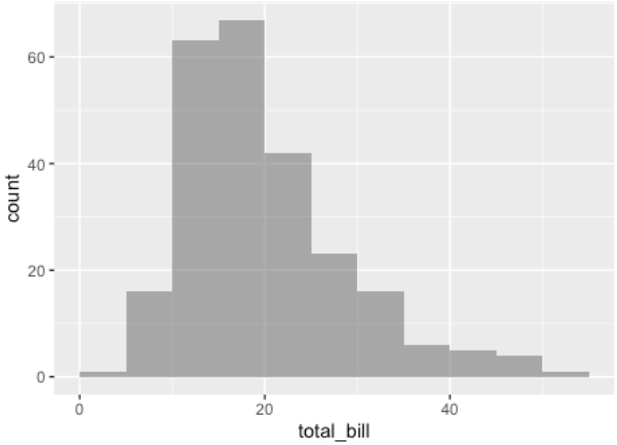


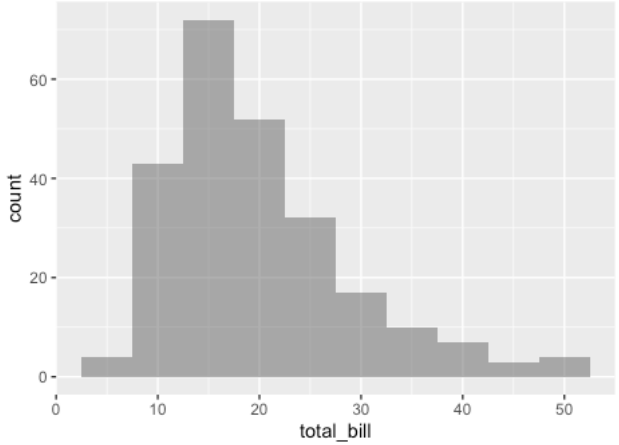
Antwort **b)** ist korrekt, da der Balken am höchsten ist – bei gleicher Balkenbreite, somit in dieser Klasse prozentual am meisten Beobachtungen sind.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Analyse Rechnungshöhe

```
gf_histogram( ~ total_bill, # Variable, die analysiert wird
         data = tips,
     binwidth = 5, # Breite einer Säule entspricht 5$
     center = 2.5) # stellt sicher, dass die Klassen von 0-5,5-10,… gehen
```



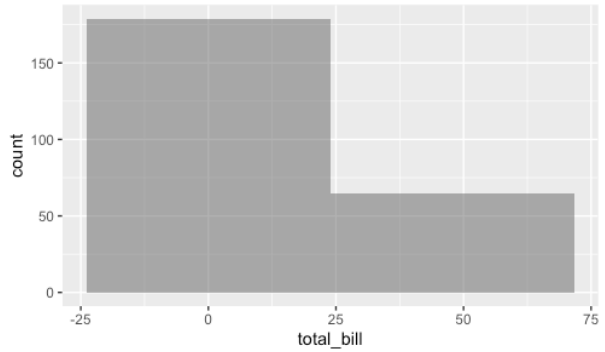



```
gf_histogram( ~ total_bill, # Variable, die analysiert wird
         data = tips,
     binwidth = 5, # Breite einer Säule entspricht 5$
                   # ohne center-Angabe sind die Klassenmitten 5,10,15,…
```

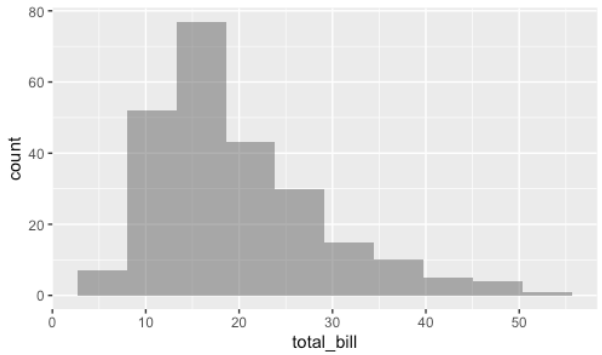

© 2026 – Hochschule der Bayerischen Wirtschaft

Histogramm: Anzahl der Klassen festlegen mit Option bins =

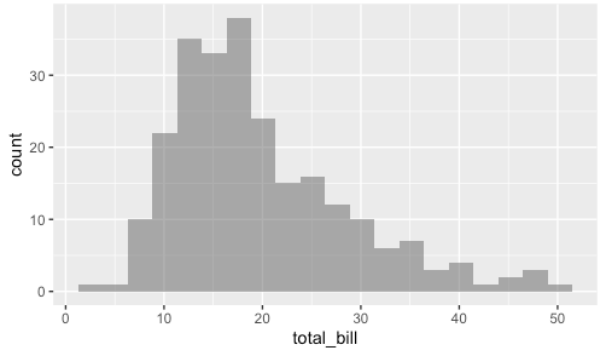
`bins = 2`



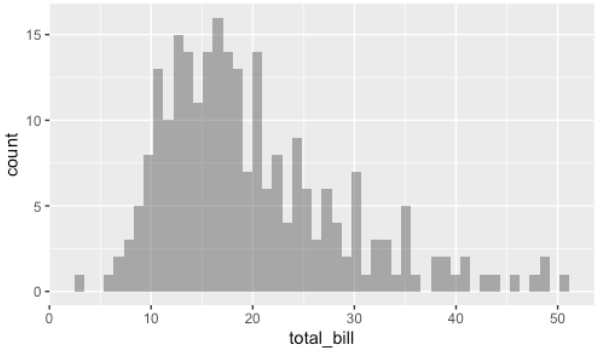
`bins = 10`



`bins = 20`



`bins = 50`



© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: Verteilung Trinkgeld

Erstellen Sie ein Histogramm für die Variable `tip`. Wählen Sie geeignete Klassenbreiten.

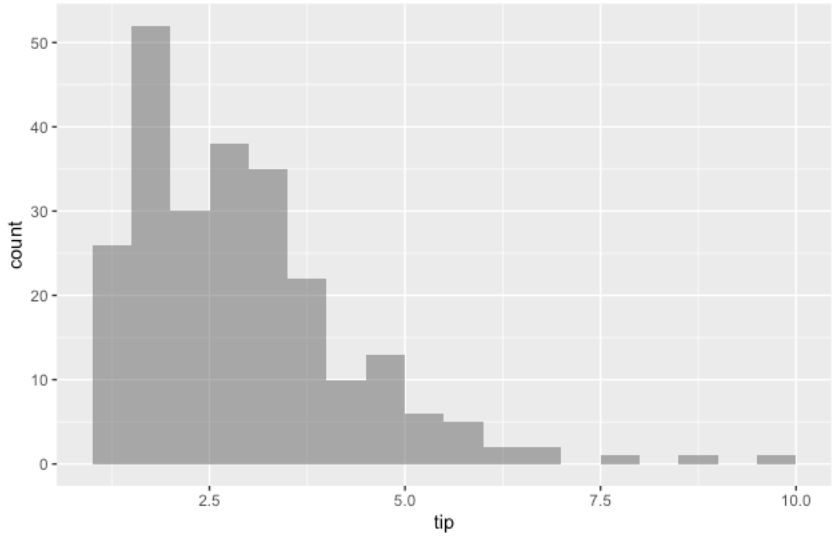
© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: Verteilung Trinkgeld

Erstellen Sie ein Histogramm für die Variable `tip`. Wählen Sie geeignete Klassenbreiten.

Eine mögliche Lösung:

```
gf_histogram( ~ tip, binwidth = 0.5, center = 0.25, data = tips)
```



© 2026 – Hochschule der Bayerischen Wirtschaft

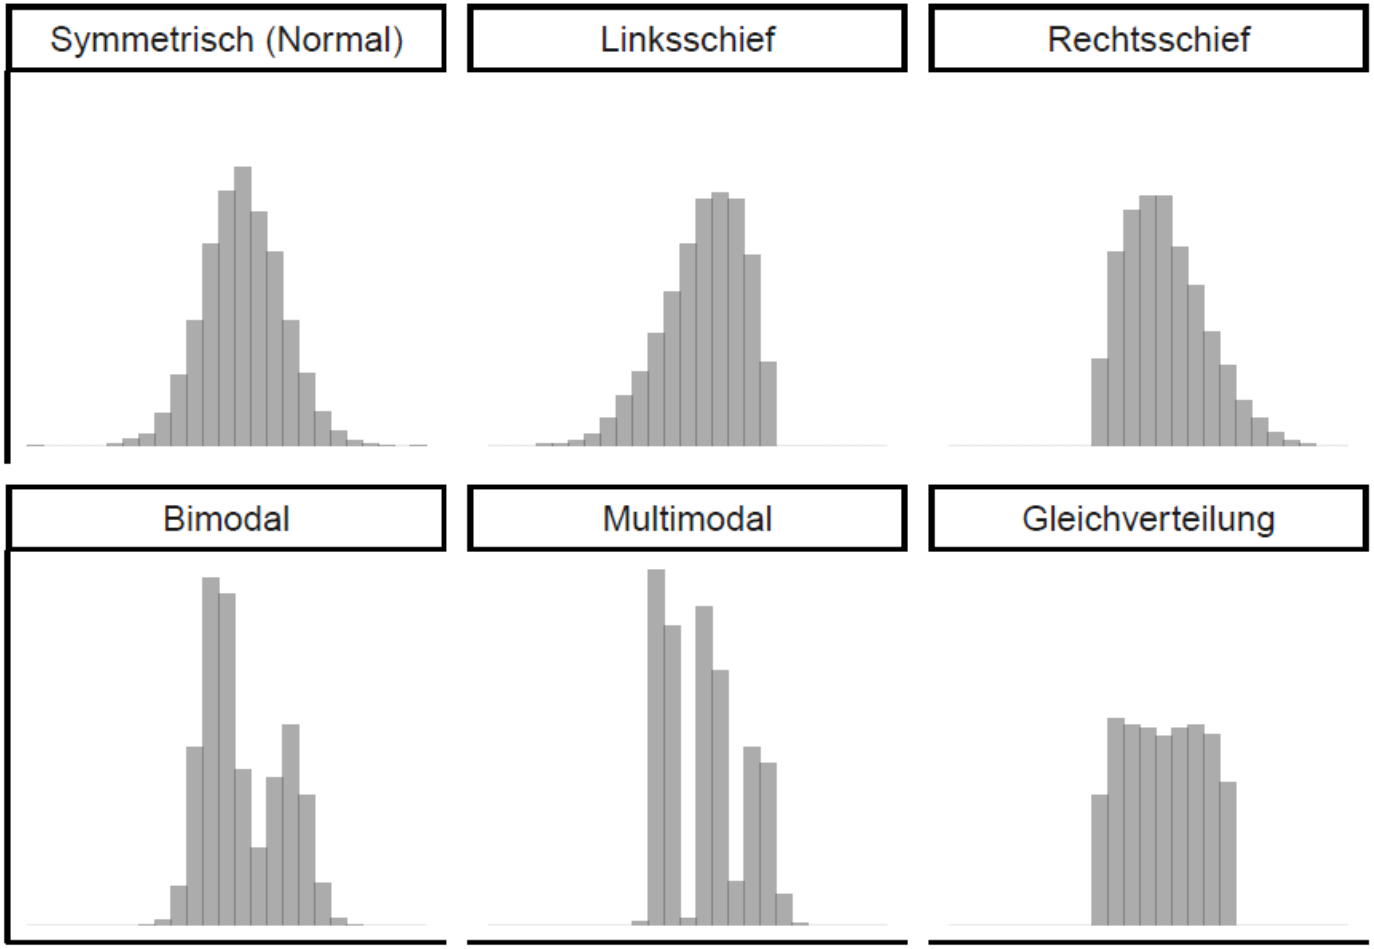
Explorative Datenanalyse
Verteilungen

Die Verteilung gibt an, wie häufig bzw. wahrscheinlich bestimmte Werte oder Wertebereiche sind.

- Schiefe: Bei **rechtsschiefen** (linkssteilen) Verteilungen sind mehr Werte im unteren Wertebereich, bei **linksschiefen** (rechtssteilen) im oberen.
- Bei **symmetrischen** Verteilungen verteilen sich die Daten symmetrisch um eine zentrale Lage.
- Bei **mehrgipfligen** Verteilungen gibt es mehr als nur ein Zentrum, um das die Werte streuen.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Verteilungsformen



© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Verteilungsform

Welche Aussage stimmt vermutlich für die Verteilung des Einkommens?

a) Das Einkommen ist gleichverteilt.
b) Das Einkommen ist multimodal.
c) Das Einkommen ist normalverteilt.
d) Das Einkommen ist linksschief.
e) Das Einkommen ist rechtsschief.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: Verteilungsform

Welche Aussage stimmt vermutlich für die Verteilung des Einkommens?

a) Das Einkommen ist gleichverteilt.
b) Das Einkommen ist multimodal.
c) Das Einkommen ist normalverteilt.
d) Das Einkommen ist linksschief.
e) Das Einkommen ist rechtsschief.

Da, grob gesagt, nur wenige viel und sehr viel verdienen, viele ein mittleres Einkommen haben und etwas weniger ein geringes, wird die Verteilung rechtsschief sein. Antwort **e)** ist also korrekt.

Hausaufgabe: Recherchieren Sie doch mal die Einkommensverteilung in Deutschland.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Rechnungshöhe

Was gilt für die Variable Rechnungshöhe `total_bill`?

a) Es ist eine latente verhältnisskalierte Variable.
b) Es ist eine manifeste verhältnisskalierte Variable.
c) Es ist eine latente intervallskalierte Variable.
d) Es ist eine manifeste intervallskalierte Variable.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: Rechnungshöhe

Was gilt für die Variable Rechnungshöhe `total_bill`?

a) Es ist eine latente verhältnisskalierte Variable.
b) Es ist eine manifeste verhältnisskalierte Variable.
c) Es ist eine latente intervallskalierte Variable.
d) Es ist eine manifeste intervallskalierte Variable.

Die Rechnungshöhe lässt sich direkt messen, also ist sie **manifest**.

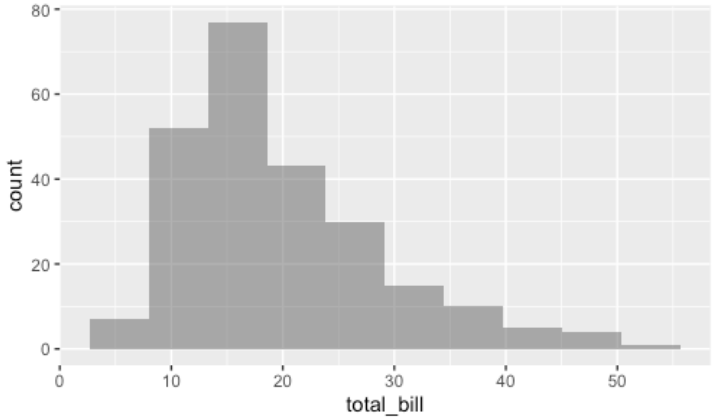
Da es einen absoluten Nullpunkt gibt, ist sie **verhältnisskaliert**, also ist **b)** korrekt.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Rechnungshöhe

Welche der folgenden Aussagen stimmt?

a) Die Rechnungshöhe ist gleichverteilt.
b) Die Rechnungshöhe ist multimodal.
c) Die Rechnungshöhe ist normalverteilt.
d) Die Rechnungshöhe ist linksschief.
e) Die Rechnungshöhe ist rechtsschief.

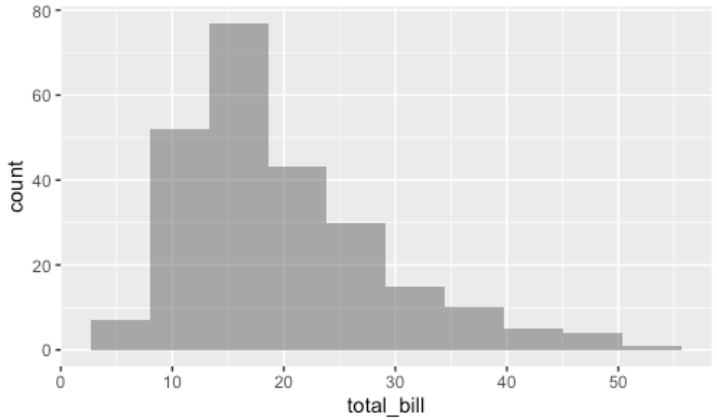


© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: Rechnungshöhe

Welche der folgenden Aussagen stimmt?

a) Die Rechnungshöhe ist gleichverteilt.
b) Die Rechnungshöhe ist multimodal.
c) Die Rechnungshöhe ist normalverteilt.
d) Die Rechnungshöhe ist linksschief.
e) Die Rechnungshöhe ist rechtsschief.



Die Rechnungshöhe hat eine Spitze, ist also unimodal.

Sie fällt nach rechts hin flacher ab, als sie links steigt, somit ist sie rechtsschief **(e)**).

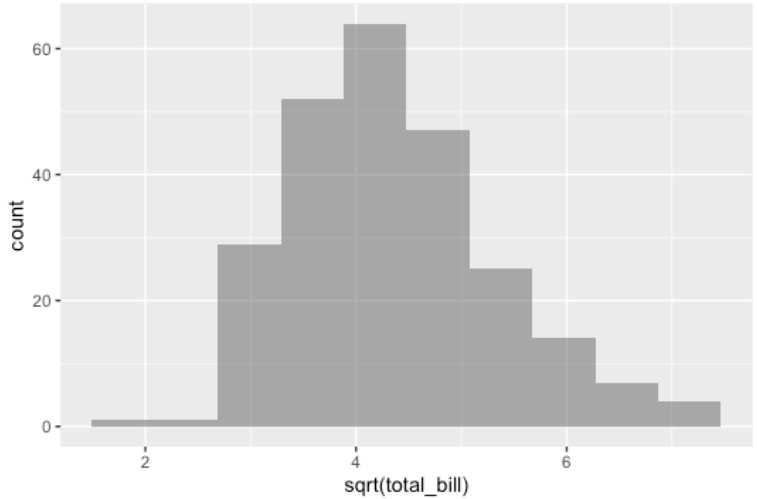
Bei (annähernder) Gleichverteilung wären alle Balken etwa gleich hoch, die Normalverteilung ist symmetrisch.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Variablentransformation

Ggfs. können Variablen durch Transformationen (z. B. $\sqrt{(\,)}$, $\ln(\,)$, …) [1] in Richtung einer symmetrischen Normalverteilung transformiert werden:

```
gf_histogram( ~ sqrt(total_bill),    # Quadratwurzel der Variable
          bins = 10,     # Anzahl Säulen
          data = tips)   # Datensatz
```



Alternative:

```
tips$wurzel_bill <- sqrt(tips$total_bill) # Neue Variable in Datenframe tips hinzufügen/berechnen
gf_histogram( ~ wurzel_bill,    # Variable
          bins = 10,     # Anzahl Säulen
          data = tips)   # Datensatz
```

[1] Hinweis: $\sqrt{(\,)}$, mit $\mathrm{sqrt}(\,)$, $\ln(\,)$ mit $\log(\,)$

© 2026 – Hochschule der Bayerischen Wirtschaft

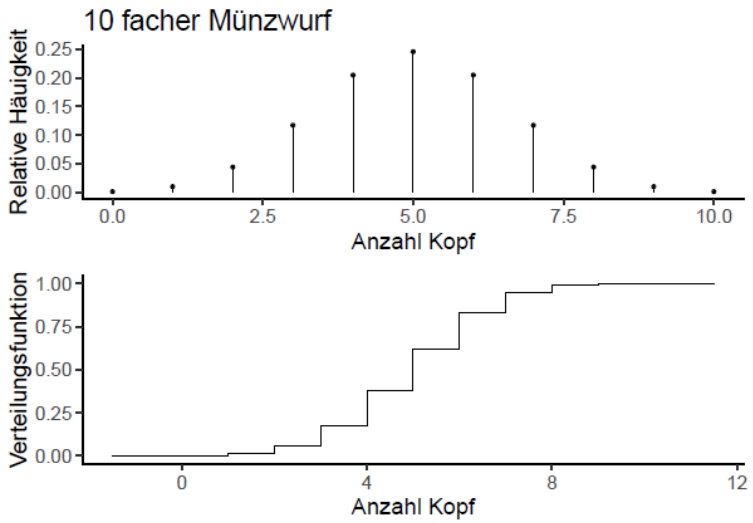
Explorative Datenanalyse
Verteilungsfunktion

Wiederholung Statistik

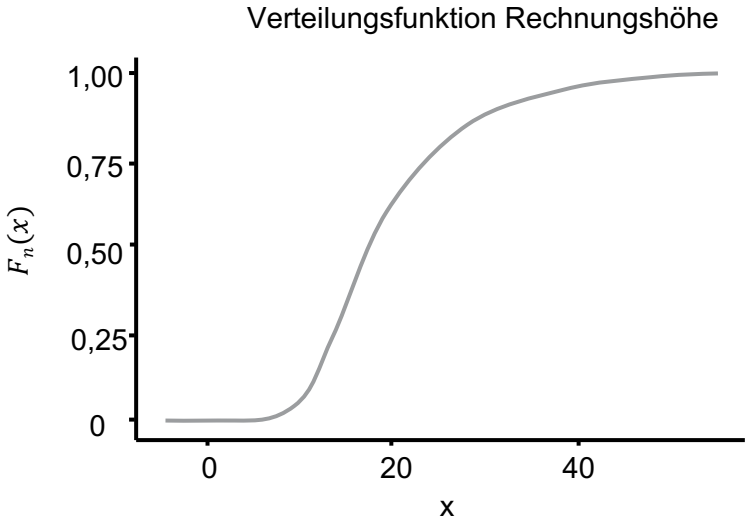
Die **empirische Verteilungsfunktion**[1] $F_n(x)$ gibt an, wie viele der n Beobachtungen kleiner oder gleich x sind:

$$F_n(x) = \frac{Anzahl\ Beobachtungen \leq x}{n}$$

Diskrete Verteilung



Stetige Verteilung



[1] Neben der *empirischen* Verteilungsfunktion gibt es auch eine *theoretische* Verteilungsfunktion $F(x)$.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Verteilungsfunktion

Für die Rechnungshöhe gilt: $F_n(10) = 0{,}07$:

```
pdata( ~ total_bill, q = 10, data = tips)
```

```
[1] 0.06967213
```

Welche Aussage stimmt?

a) Die relative Häufigkeit einer Rechnungshöhe von 10 $ liegt bei 0.07.

b) Die relative Häufigkeit einer Rechnungshöhe von mindestens 10 $ liegt bei 0.07.

c) Die relative Häufigkeit einer Rechnungshöhe von höchstens 10 $ liegt bei liegt bei 0.07.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: Verteilungsfunktion

Für die Rechnungshöhe gilt: $F_n(10) = 0{,}07$:

```
pdata( ~ total_bill, q = 10, data = tips)
```

```
[1] 0.06967213
```

Welche Aussage stimmt?

a) Die relative Häufigkeit einer Rechnungshöhe von 10 $ liegt bei 0.07.
b) Die relative Häufigkeit einer Rechnungshöhe von mindestens 10 $ liegt bei 0.07.
c) Die relative Häufigkeit einer Rechnungshöhe von höchstens 10 $ liegt bei liegt bei 0.07.

Die (empirische) Verteilungsfunktion sagt aus, wie groß der Anteil der Beobachtungen ist, die $\leq x$ sind, also **c).** Damit liegt dir relative Häufigkeit einer Rechnungshöhe **über** 10 $ bei $1 - F_n(10) = 0.93$.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lagemaße

Wiederholung Statistik

Lagemaße sollen u. a. die zentrale Tendenz der Daten beschreiben:

- **Minimum** bzw. **Maximum**: Kleinste bzw. größte Merkmalsausprägung.
- **Modus** / Modalwert: Häufigste Merkmalsausprägung.
- **Median** / Zentralwert: Merkmalsausprägung, die bei (aufsteigend) sortierten Beobachtungen in der Mitte liegt;
- **Arithmetischer Mittelwert** (engl. mean) [1]: Summe aller Werte geteilt durch die Anzahl: $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$;
- **Quantil**: Das p-Quantil ist der Wert, für den gilt, dass er von p Prozent der Werte nicht überschritten wird.
- **Quartile:** Q1 = 25%-Quantil, Q2 = 50%-Quantil, Q3 = 75%-Quantil.

[1] Darüber hinaus gibt es noch den Geometrischen und den Harmonischen Mittelwert.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Beispielrechnung Lagemaße

Wiederholung Statistik

Daten: 20; 18; 24; 40; 24; 22; 21; 23; 20; 28 ($n = 10$)

- Minimum, Maximum, Modus: $x_{min} = 18,\ x_{max} = 40,\ x_{mod} = \{20; 24\}$
- Median: 18; 20; 20; 21; 22; 23; 24; 24; 28; 40

$$x_{0,5} = \frac{22+23}{2} = 22{,}5$$

- Arithmetischer Mittelwert: $\bar{x} = \frac{1}{10}(20 + 18 + 24 + \cdots + 28) = \frac{240}{10} = 24$
- 25 %-Quantil: $x_{0,25} = 20$

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Beispiel Quantil

Das 90%-Quantil der Rechnungshöhe liegt bei 32.24 $:

```
qdata( ~ total_bill, p = 0.9, data = tips)
```

```
 90%
32.235
```

- 90% der Rechnungen sind kleiner oder gleich 32.24 $.
- $1 - 90\% = 10\%$ der Rechnungen sind größer oder gleich 32.24 $.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Lagemaße

Wiederholung Statistik

Stimmt die Aussage: Es gilt immer $F_n(\bar{x}) = 0.5$?

a) Ja.

b) Nein.

© 2026 – Hochschule der Bayerischen Wirtschaft

Wiederholung Statistik

Stimmt die Aussage: Es gilt immer $F_n(\bar{x}) = 0.5$?

a) Ja.

b) Nein.

b) Nein,

… während für den Median nach Definition gilt $F_n(x_{0,5}) = 0.5$ gilt dies für den Mittelwert beispielsweise bei symmetrischen Verteilungen, aber nicht z. B. bei schiefen Verteilungen.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Mittelwert als “Modell”

Idee:

```
Daten = Modell + Rest.
```

```
mean( ~ total_bill, data = tips)
```

```
[1] 19.78594
```

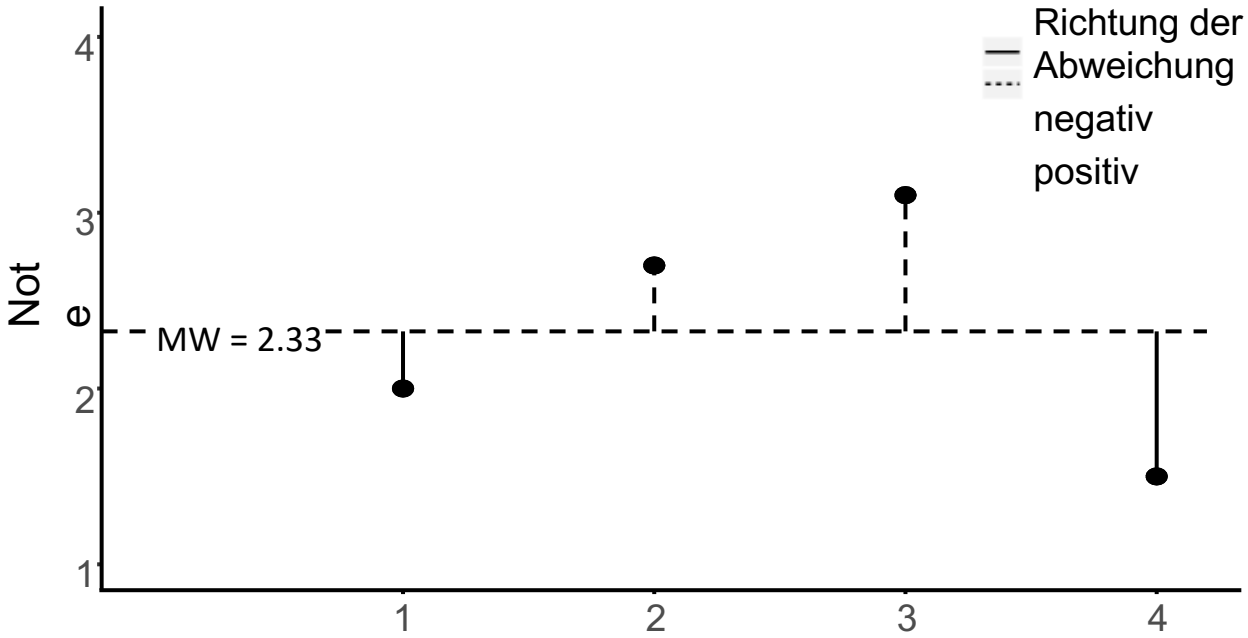
- Für Beobachtung i gilt: $x_i = \bar{x} + (x_i - \bar{x})$.
- Der „Rest” (Residuum) $x_i - \bar{x}$ zeigt die Abweichung der Beobachtung zum Mittelwert $\bar{x}$ (hier: “Modell”) an.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Abweichungen vom Mittelwert

Wiederholung Statistik

Die Abweichungen vom Mittelwert summieren sich zu Null auf



$$\sum_{i=1}^{n}(xi - \bar{x}) = \sum_{i=1}^{n} x_i - \sum_{i=1}^{n} \bar{x} = n \cdot \bar{x} - n \cdot \bar{x} = 0$$

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Streuungsmaße

Wiederholung Statistik

Streuungsmaße sollen die Streuung / Variation der Daten beschreiben:

- **Varianz:** Maß für die durchschnittliche quadratische Abweichung zum Mittelwert: $s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$. Diese hat aber eine andere Einheit als die Daten, z. B. Daten in €, Varianz €^{2}. Durch das Quadrieren werden Abweichungen zum Mittelwert nach oben oder unten gleich behandelt und größere Abweichungen stärker gewichtet.[1]
- **Standardabweichung** (engl. standard deviation): Quadratwurzel der Varianz: $sd = s = \sqrt{s^2}$.
- **Interquartilsabstand** (engl. interquartile range, IQR): Oberes Quartil (75%-Quantil) – unteres Quartil (25%-Quantil).
- **Spannweite** (engl. range): Maximum – Minimum.

[1] $1/n$ ist nicht im eigentlichen Sinne falsch.
$1/(n-1)$ ist aus Gründen, die außerhalb dieses Moduls liegen, besser, wenn von einer Stichprobe auf die Varianz der Population (σ^2) verallgemeinert werden soll. Der Unterschied ist bei großem n klein.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Beispielrechnung Streuungsmaße

Wiederholung Statistik

Daten: 20; 18; 24; 40; 24; 22; 21; 23; 20; 28, $n = 10$, $\bar{x} = 24$

- Varianz:

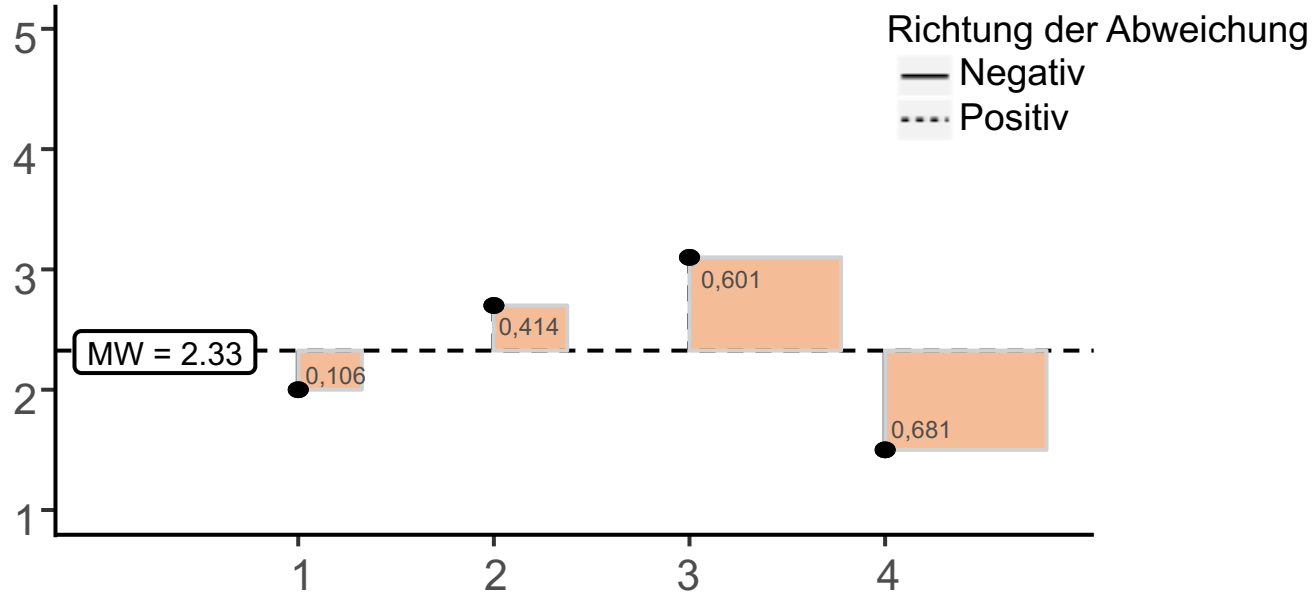
$$s^2 = \frac{1}{10-1} = \left((20-24)^2 + (18-24)^2 + \cdots + (28-24)^2\right) = \frac{354}{9} \approx 39{,}33$$

- Standardabweichung: $sd = \sqrt{39{,}33} = 6{,}27$
- Interquartilsabstand [1]: $IQR = 24 - 20 = 4$
- Spannweite: $40 - 18 = 22$.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Varianz und SD als “Abweichungsquadrate”

Wiederholung Statistik



$$s^2 \approx \frac{1}{4-1} \cdot (0.106 + 0.141 + 0.601 + 0.681) = 0.509$$

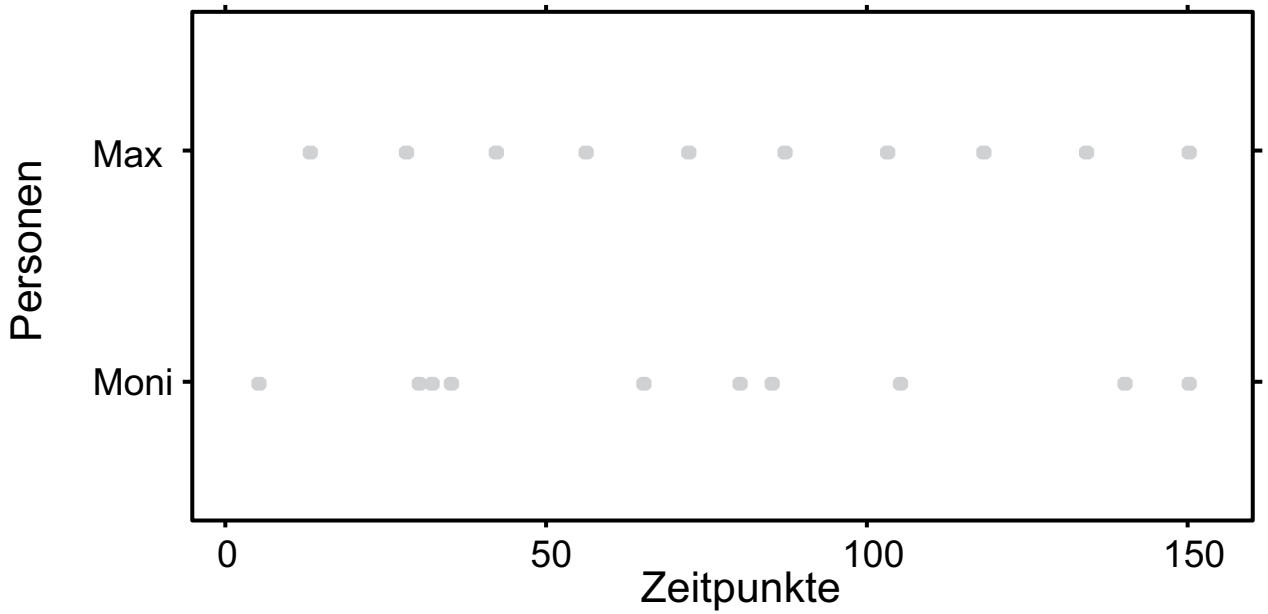
Abweichungsquadrate als Kennzahl für „Rest“:

- `Daten = Modell + Rest:` $x_i = \bar{x} + (xi - \bar{x})$.
- Quadratsumme des Restes: $\sum_{i=1}^{n}(x_i - \bar{x})^2 = (n-1) \cdot s^2 = (n-1) \cdot sd^2$.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Beispiel: Abwanderungserkennung

- Während Max sehr regelmäßig einkauft (kleine Streuung), kauft Moni zwar genau so oft, aber unregelmäßiger ein.



- Beide waren seit 30 Tagen nicht mehr einkaufen: Aufgrund der größeren Streuung der Kaufintervalle ist dies bei Moni **üblicher** als bei Max.[1]

[1] Vgl. z. B. Papenhoff, H., Lübke, K. (Management, 2017): Churn Management – Herausforderungen für den Handel, in: Helmke, S. et al. (Hg.) Effektives Customer Relationship Management, S. 161–170.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: z-Wert

z-Transformation (Studentisierung):
Überführung einer Verteilung in eine mit $\bar{z} = 0$ und $sd_z = 1$:

$$z_i = \frac{x_i - \bar{x}}{sd_x}$$

Kunde A hat bei 30 Tagen nicht einkaufen einen z-Wert von 1, Kunde B einen von 2. Welcher Kunde ist abwanderungsgefährdeter?

a) A.
b) B.
c) Kann mit der gegebenen Information nicht entschieden werden.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: z-Wert

z-Transformation (Studentisierung):
Überführung einer Verteilung in eine mit $\bar{z} = 0$ und $sd_z = 1$:

$$z_i = \frac{x_i - \bar{x}}{sd_x}$$

Kunde A hat bei 30 Tagen nicht einkaufen einen z-Wert von 1, Kunde B einen von 2. Welcher Kunde ist abwanderungsgefährdeter?

a) A.

b) B.

c) Kann mit der gegebenen Information nicht entschieden werden.

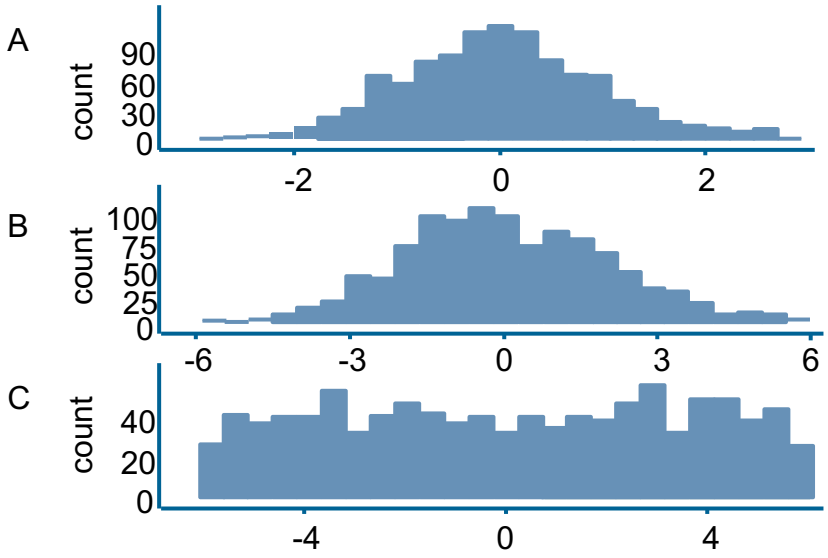
b),

… Der Zähler $x_i - \bar{x}$ gibt an ob der Wert x_i über oder unter dem (jeweiligen) Mittelwert $\bar{x}$ liegt. Durch die Standardisierung (Division durch die jeweilige sd_x) wird die Abweichung zum Mittelwert relativiert: Wie groß ist die Abweichung. Die Abweichung zum Mittelwert ist bei B (relativ) größer: Während die Dauer der Abwesenheit von A eine Standardabweichung über seinem Mittelwert liegt, liegt diese bei B zwei Standardabweichungen über dem Mittelwert.

Hinweis: z.B. Befehl `zscore()`.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Vergleich Streuung

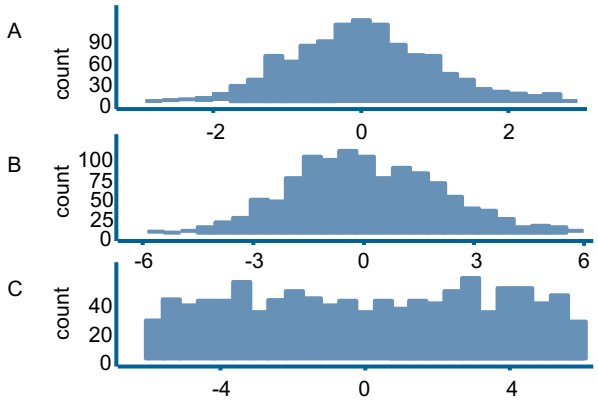


Bei welcher Abbildung ist die Standardabweichung sd wohl am größten?

a) Abbildung A.
b) Abbildung B.
c) Abbildung C.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: Vergleich Streuung



Bei welcher Abbildung ist die Standardabweichung sd wohl am größten?

a) Abbildung A.

b) Abbildung B.

c) Abbildung C.

c),

… hier liegen mehr Beobachtungen weiter vom Mittelwert entfernt als bei B. (Die Beobachtungen in B streuen auch mehr als die Werte in A.) Relevant ist die Variation der Werte (x-Achse), nicht der Häufigkeit (y-Achse).

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Trinkgeld-Datensatz

`inspect()` **inspiziert** den Datensatz und gibt eine Übersicht über wesentliche Kennzahlen.

```
inspect(tips)
```

```
categorical variables:
    name     class levels   n missing                                distribution
1    sex character      2 244       0 Male (64.3%), Female (35.7%)
2 smoker character      2 244       0 No (61.9%), Yes (38.1%)
3    day character      4 244       0 Sat (35.7%), Sun (31.1%), Thur (25.4%) ...
4   time character      2 244       0 Dinner (72.1%), Lunch (27.9%)

quantitative variables:
           name   class  min      Q1 median      Q3   max      mean        sd   n missing
...1 total_bill numeric 3.07 13.3475 17.795 24.1275 50.81 19.785943 8.9024120 244       0
...2        tip numeric 1.00  2.0000  2.900  3.5625 10.00  2.998279 1.3836382 244       0
...3       size integer 1.00  2.0000  2.000  3.0000  6.00  2.569672 0.9510998 244       0
```


© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Metrische Variablen

Wie viele metrische Variablen liegen vor?

a) 2
b) 3
c) 4
d) 7
e) 244

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: Metrische Variablen

Wie viele metrische Variablen liegen vor?

a) 2
b) 3
c) 4
d) 7
e) 244

- Es liegen **3 (Antwort b))** metrische (numerische) Variablen vor (`total_bill, tip, size`), die anderen sind kategoriale (bzw. nominalskalierte) Variablen.
- 7 ist die Gesamtzahl an Variablen und 244 ist die Anzahl der Beobachtungen.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Kennzahlen: Rechnungshöhe

Analysiere über Kennzahlen:

```
favstats( ~ total_bill,  # Variable, die analysiert wird
       data = tips)  # Datensatz
```

```
 min      Q1 median      Q3   max     mean       sd   n missing
3.07 13.3475 17.795 24.1275 50.81 19.78594 8.902412 244       0
```


© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Kennzahlen

Analysiere über Kennzahlen:

```
favstats( ~ total_bill,  # Variable, die analysiert wird
       data = tips)  # Datensatz
```

```
 min      Q1 median      Q3   max     mean       sd   n missing
3.07 13.3475 17.795 24.1275 50.81 19.78594 8.902412 244       0
```

Im welchen Bereich liegen 50% der Beobachtungen der Rechnungshöhe?

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: Kennzahlen

Analysiere über Kennzahlen:

```
favstats( ~ total_bill,  # Variable, die analysiert wird
       data = tips)  # Datensatz
```

```
 min      Q1 median      Q3   max     mean       sd   n missing
3.07 13.3475 17.795 24.1275 50.81 19.78594 8.902412 244       0
```

Im welchen Bereich liegen 50% der Beobachtungen der Rechnungshöhe?

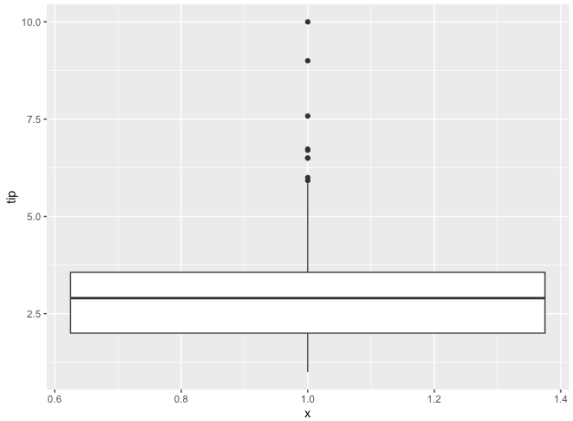
Die mittleren 50% liegen im Bereich `Q1` bis `Q3`. Dies sind die Beobachtungswerte innerhalb des Interquartilsabstands (IQR). Aber auch zwischen `min` und `median` bzw. zwischen `median` und `max` (jeweils einschließlich) liegen 50% der Beobachtungen.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Boxplot

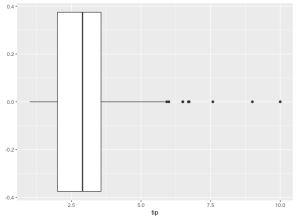
Der **Boxplot** visualisiert die Verteilung von deskriptiven Kennzahlen und mögliche Ausreißer einer numerischen Variable.

```
gf_boxplot(tip ~ 1, data = tips)
```




```
gf_boxplot(~ tip, data = tips)
```

liefert einen horizontalen Boxplot.



© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Struktur eines Boxplot

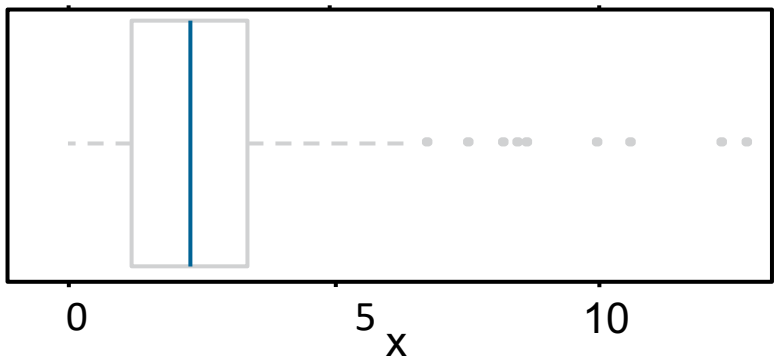
- Die **untere Linie** der Box ist das **untere Quartil** (25%-Quantil, Q1).
- Die **obere Linie** der Box ist das **obere Quartil** (75%-Quantil, Q3).
- Der Linie **in der Box** (gelegentlich auch Punkt) ist der **Median**.
- Sollten **Punkte** außerhalb der Antennen sein, sind dies **mögliche Ausreißer**.
- Maximale **Reichweite der Antennen**:
  Bis zu der Beobachtung, die **maximal** $1{,}5 \cdot IQR$ vom oberen bzw. unteren Quartil entfernt liegt. Sollte das Maximum der Daten kleiner bzw. das Minimum größer sein, wird dieses genommen.[1]

[1] Definition nicht immer einheitlich

© 2026 – Hochschule der Bayerischen Wirtschaft

Verknüpfe Abbildung und Kennzahlen.

Ab wann ist eine Beobachtung ein potentieller Ausreißer nach oben?

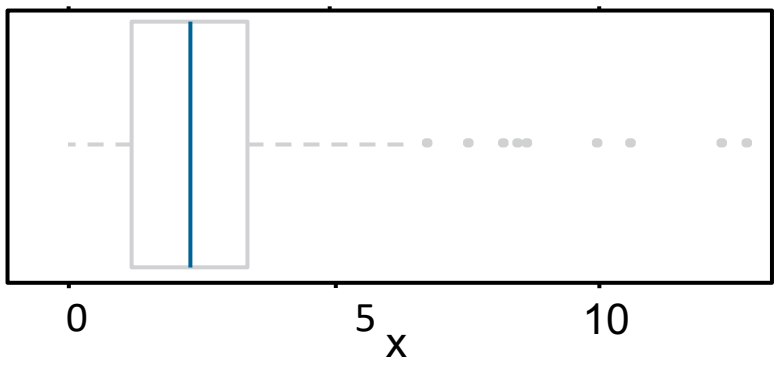


min	Q1	median	Q3	max	mean	sd	n	missing
0.11	1.3	2.36	3.4	12.63	2.96	2.65	100	0

© 2026 – Hochschule der Bayerischen Wirtschaft

Verknüpfe Abbildung und Kennzahlen.

Ab wann ist eine Beobachtung ein potentieller Ausreißer nach oben?



min	Q1	median	Q3	max	mean	sd	n	missing
0.11	1.3	2.36	3.4	12.63	2.96	2.65	100	0

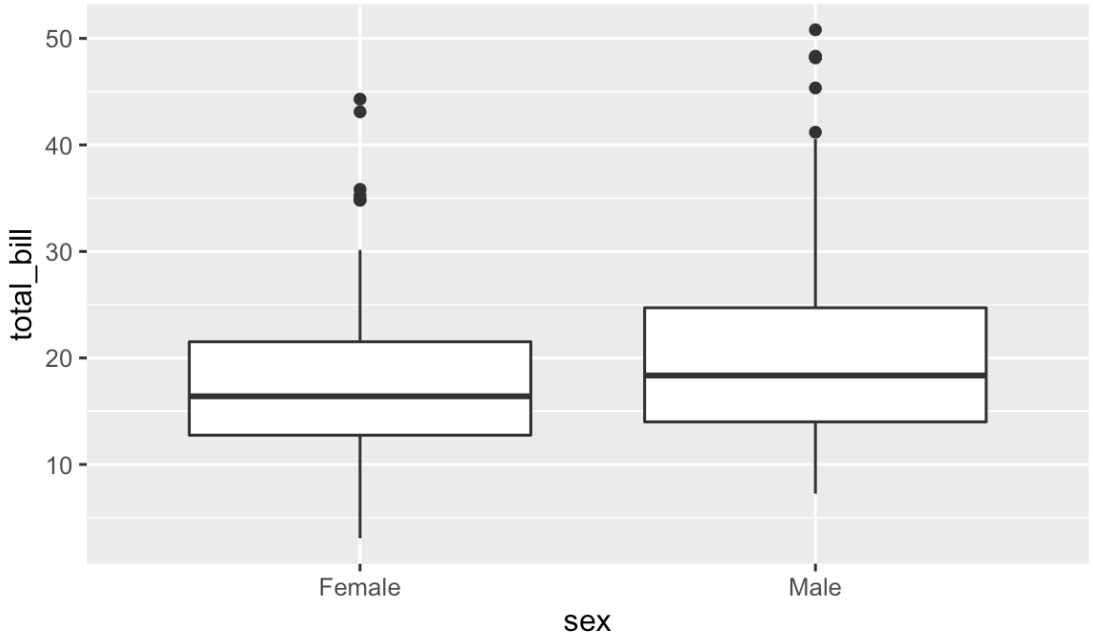
- Es ist $IQR = 3.4 - 1.3 = 2.1$ und $1{,}5 \cdot IQR = 3.15$.
- Die obere Antenne liegt daher bei $3.4 + 3.15 = 6.55$.
- Also können Werte als Ausreißer nach oben gelten, wenn sie größer als 6.55 sind.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Boxplot Rechnungshöhe abhängig vom Geschlecht

Analysiere über Boxplot

```
gf_boxplot(total_bill ~ # abhängige Variable
         sex,           # unabhängige Variable
         data = tips)   # Datensatz
```

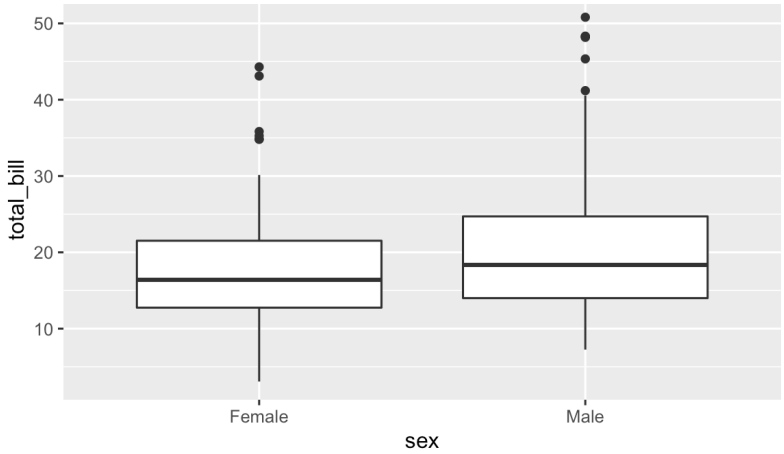


© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Boxplot

Welche Aussage stimmt nach der Abbildung?

a) Der Mittelwert der Rechnungshöhe ist bei den Männern unter 20$.
b) Der Mittelwert der Rechnungshöhe ist bei den Männern über 20$.
c) Der Median der Rechnungshöhe ist bei den Männern unter 20$.
d) Der Median der Rechnungshöhe ist bei den Männern über 20$.

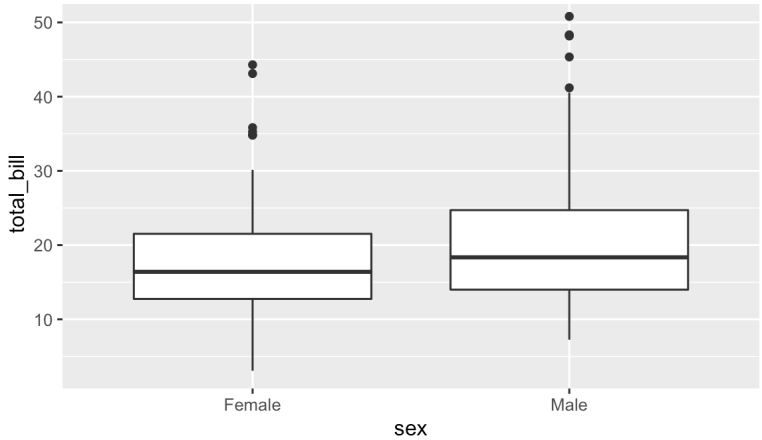


© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: Boxplot

Welche Aussage stimmt nach der Abbildung?

a) Der Mittelwert der Rechnungshöhe ist bei den Männern unter 20$.
b) Der Mittelwert der Rechnungshöhe ist bei den Männern über 20$.
c) Der Median der Rechnungshöhe ist bei den Männern unter 20$.
d) Der Median der Rechnungshöhe ist bei den Männern über 20$.



Die Mittelwerte werden in diesen Boxplots nicht mit ausgegeben, daher können die Antworten **a)** und **b)** nicht beurteilt werden. Der Median (die Linie in der Box) liegt bei den Männern noch knapp unter 20$, somit ist Antwort **c)** korrekt.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Kennzahlen / Diagramme gruppiert nach Geschlecht

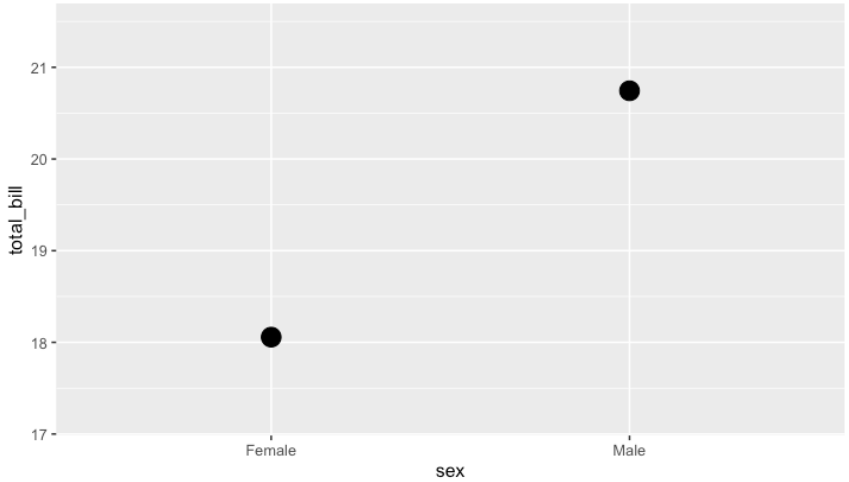
Zusammenfassende Kennzahlen je **Geschlecht**:

```
favstats(total_bill ~ sex, data = tips)
```

```
     sex  min    Q1 median    Q3   max     mean       sd   n missing
1 Female 3.07 12.75  16.40 21.52 44.30 18.05690 8.009209  87       0
2   Male 7.25 14.00  18.35 24.71 50.81 20.74408 9.246469 157       0
```

Zusammenfassendes Diagramm je **Mittelwert** von Geschlecht:[1]

```
gf_point(total_bill ~ sex, stat = "summary", size = 5, data = tips)
```



[1] mit `gf_point(total_bill ~ sex, stat = "summary", color = "blue", size = 5, data = tips)` wird's bunt.

© 2026 – Hochschule der Bayerischen Wirtschaft

Idee:

$$Daten = Modell + Rest$$

Modell:

- Gesamtmittelwert $\bar{x}$, d. h. keine die Rechnungshöhe modellierende Variable:

```
favstats(total_bill ~ 1, data = tips)
```

```
  1  min      Q1 median      Q3   max     mean       sd   n missing
1 1 3.07 13.3475 17.795 24.1275 50.81 19.78594 8.902412 244       0
```

$$\sum_{i=1}^{n}(x_i - \overline{x})^2 = (n-1) \cdot sd^2 = (244-1) \cdot 8.902412^2 = 19258.46$$

© 2026 – Hochschule der Bayerischen Wirtschaft

Modell:

- Gesamtmittelwert $\bar{x}_j$ je Anzahl Personen $j = 1, \ldots 6$, d. h. die Rechnungshöhe wird durch die jeweilige Anzahl Personen modelliert:

```
favstats(total_bill ~ size, data = tips)
```

```
 size   min      Q1 median      Q3   max     mean       sd   n missing
1    1  3.07  6.2050  7.915  8.9525 10.07  7.24250 3.010729   4       0
2    2  5.75 12.4525 15.370 19.6900 40.55 16.44801 6.043729 156       0
3    3 10.33 16.9400 20.365 27.7750 50.81 23.27763 9.407065  38       0
4    4 16.49 21.5000 25.890 34.8100 48.33 28.61351 8.608603  37       0
5    5 20.69 28.1500 29.850 30.4600 41.19 30.06800 7.340396   5       0
6    6 27.05 29.1125 32.050 37.7675 48.17 34.83000 9.382000   4       0
```

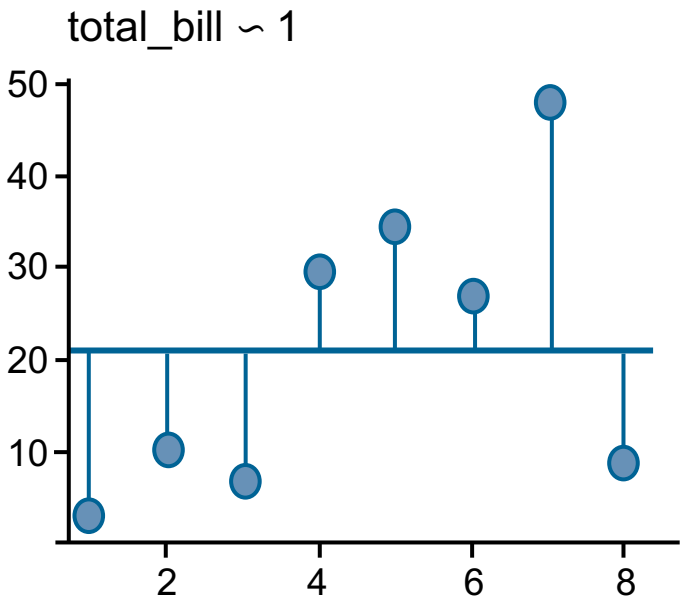
$$\sum_{j=1}^{K} \sum_{i=i}^{n_j} (x_{i,j} - \overline{x}_j)^2 = \sum_{j=1}^{K} (n_j - 1) \cdot sd_j^2 = 12110.54$$

- Bei der Analyse `total_bill ~ size` ist der **Rest** kleiner als bei der Analyse
- `total_bill ~ 1` (ohne erklärende Variable).
- Für dieses Reduzierung des Restes wird ein Preis gezahlt: In den einzelnen Gruppen sind weniger Beobachtungen: Weniger **Freiheitsgrade** (engl: degrees of freedom, df).

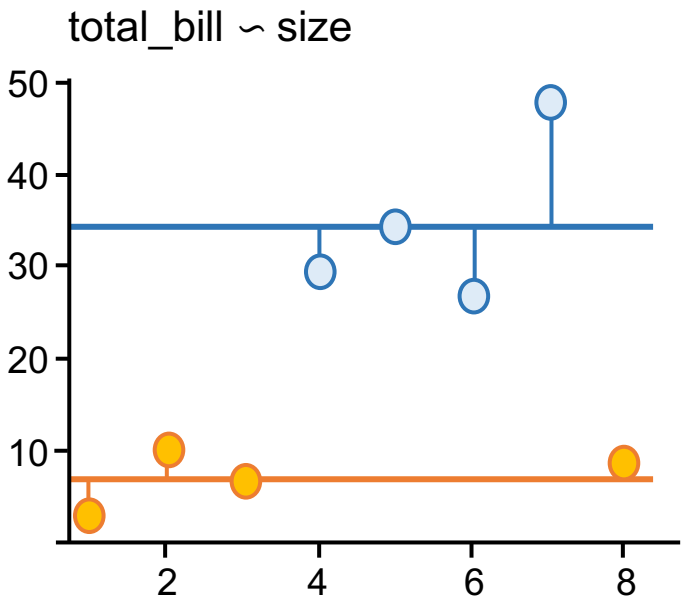
© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Modellierung

Visualisierung für den reduzierten Datensatz mit nur 1 oder 6 Personen am Tisch (`size`).



Relativ viel Residualstreuung



Relativ wenig(er) Residualstreuung

© 2026 – Hochschule der Bayerischen Wirtschaft



Kapitel 4.4

Explorative Datenanalyse

Zusammenhang zwischen numerischen Variablen

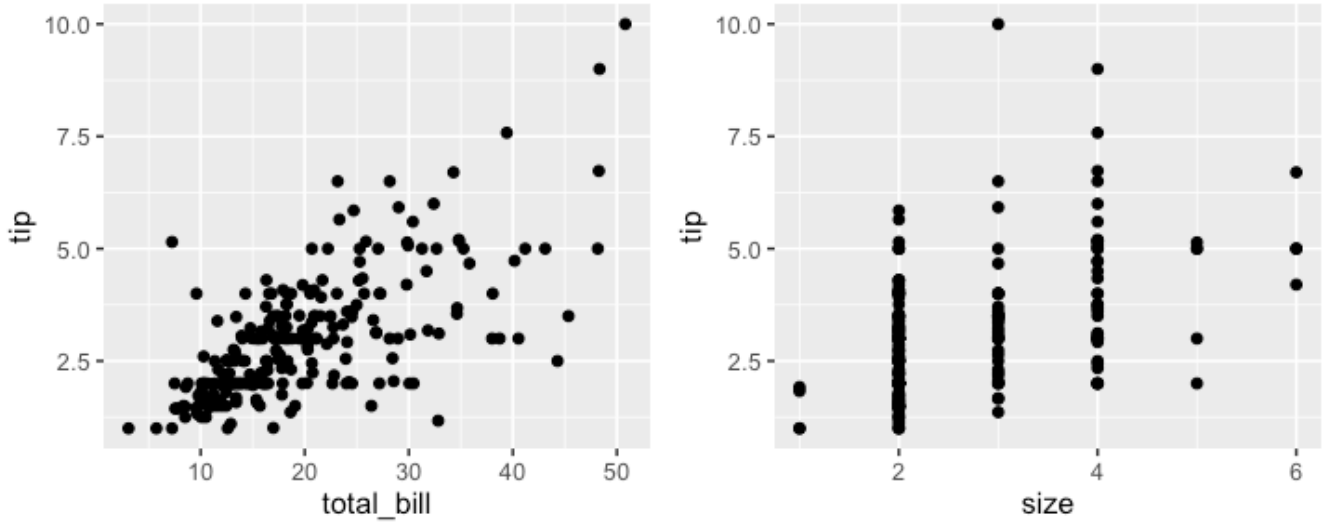
V26-10-25

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Streudiagramm

Ein **Streudiagramm** visualisiert die gemeinsame Verteilung von zwei i. d. R. numerischen Variablen durch Punkte.

```
plot1 <- gf_point(tip ~ total_bill, data = tips) # zwei stetige Variablen
plot2 <- gf_point(tip ~ size, data = tips)  # eine stetige, eine diskrete
grid.arrange(plot1, plot2, nrow = 1)
```



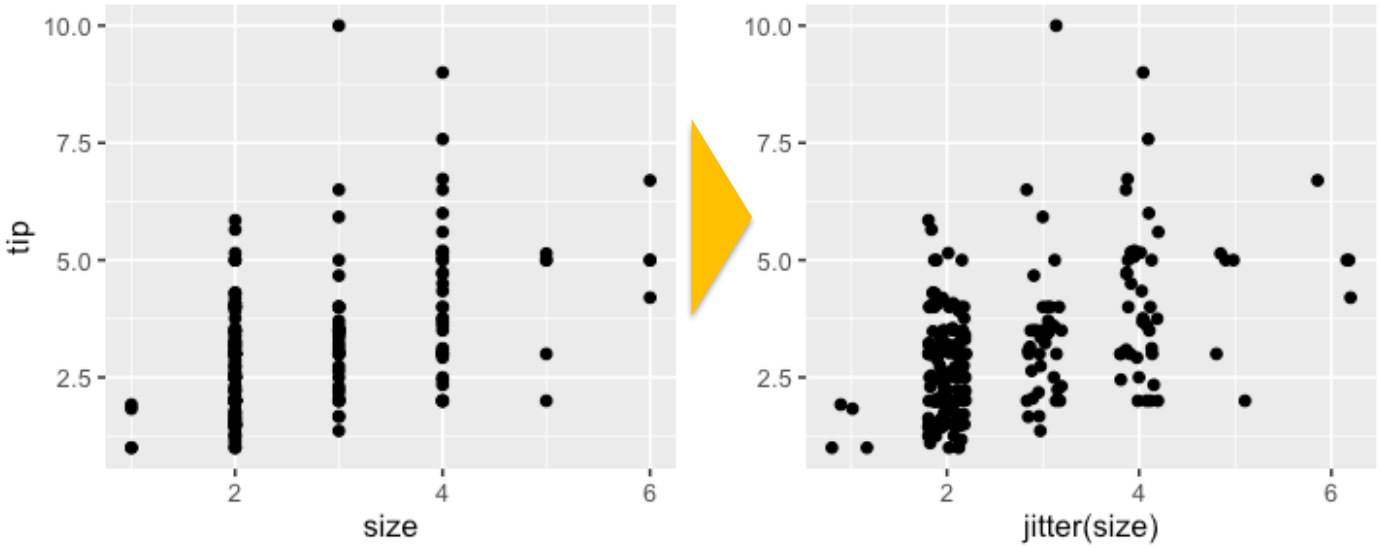
Mit dem Befehl `grid.arrange` können mehrere Grafiken strukturiert nebeneinander / übereinander angeordnet werden.
Er ist Teil des Pakets `gridExtra` → `install.packages(„gridExtra“)` → `library(gridExtra)`

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Streudiagramm

Bei diskreten Merkmalen kann es vorkommen, dass sich die einzelnen Datenpunkte überlagern, sog. **„Overplotting“**. Mit dem Befehl `jitter` werden die Punkte zufällig verwackelt.

```
plot1 <- gf_point(tip ~ size, data = tips)
plot2 <- gf_point(tip ~ jitter (size), data = tips)  #jitter (engl.) = wackeln
grid.arrange(plot1, plot2, nrow = 1)
```



© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Kovariation

Wiederholung Statistik

- **Kovarianz** beschreibt den linearen Zusammenhang zweier metrischer Merkmale:

$$s_{xy} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}).$$

- Die Werte beider Variablen einer Beobachtung werden mit dem jeweiligen Mittelwert der Variable verglichen. Vom Produkt der gemeinsamen Abweichungen wird der Mittelwert berechnet.
- Der **Korrelationskoeffizient** nach Pearson[1] $r = \frac{s_{xy}}{sd_x \cdot sd_y}$ normiert die Kovarianz auf den Wertebereich -1 bis $+1$ durch Division der Kovarianz durch das Produkt der Standardabweichungen.
- Korrelationskoeffizienten $r > 0$ zeigen einen positiven linearen Zusammenhang an, $r < 0$ einen negativen. Je größer $|r|$, desto größer ist der lineare Zusammenhang.
- **Vorsicht**: Korrelation heißt **nicht** zwangsläufig Kausalität, keine Korrelation heißt nicht zwangsläufig kein Zusammenhang oder keine Kausalität.[2]

[1] Alternative: Spearman.

[2] Scheinkorrelation, siehe z. B. http://www.tylervigen.com/spurious-correlations

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Kovariation

Wiederholung Statistik

- **Einkommen x und Ausgaben y: positiver Zusammenhang:**

  Personen mit überdurchschnittlichem Einkommen $(x_i - \bar{x} > 0)$ haben häufig auch überdurchschnittliche Ausgaben $(y_i - \bar{y} > 0)$,
  Personen mit unterdurchschnittlichem Einkommen $(x_i - \bar{x} < 0)$ haben häufig auch unterdurchschnittliche Ausgaben $(y_i - \bar{y} < 0)$.

  In beiden Fällen: $(x_i - \bar{x}) \cdot (y_i - \bar{y}) > 0$.

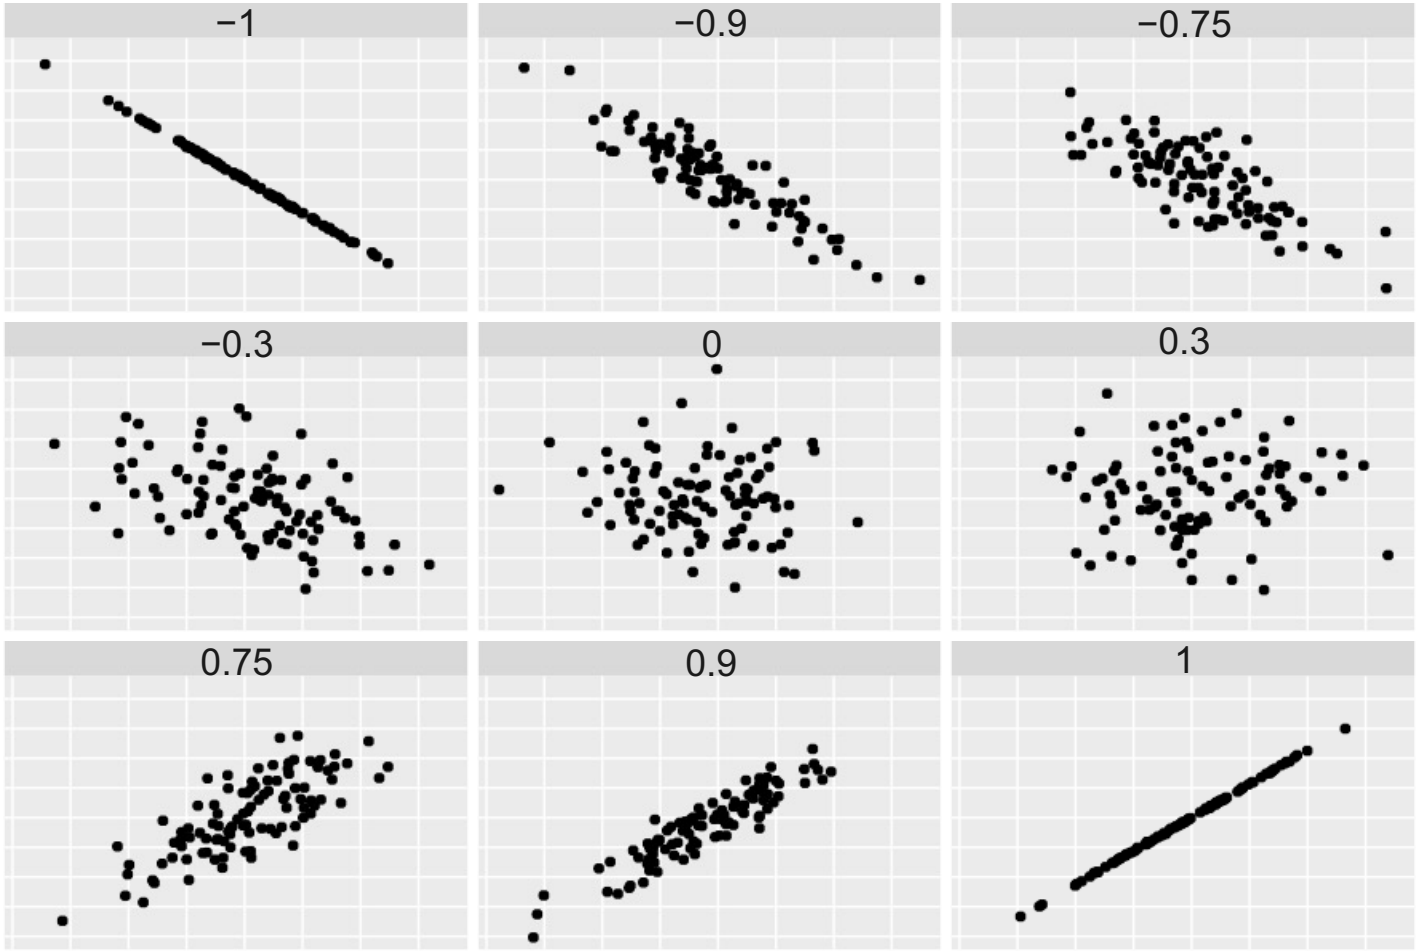
- **Preis x und Absatz y: negativer Zusammenhang:**

  Produkte mit überdurchschnittlichem Preis $(x_i - \bar{x} > 0)$ haben häufig einen unterdurchschnittlichen Absatz $(y_i - \bar{y} < 0)$,
  Produkte mit unterdurchschnittlichem Preis $(x_i - \bar{x} < 0)$ haben häufig einen überdurchschnittlichen Absatz $(y_i - \bar{y} > 0)$.

  In beiden Fällen: $(x_i - \bar{x}) \cdot (y_i - \bar{y}) < 0$.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Korrelationskoeffizient



© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Nicht lineare Zusammenhänge

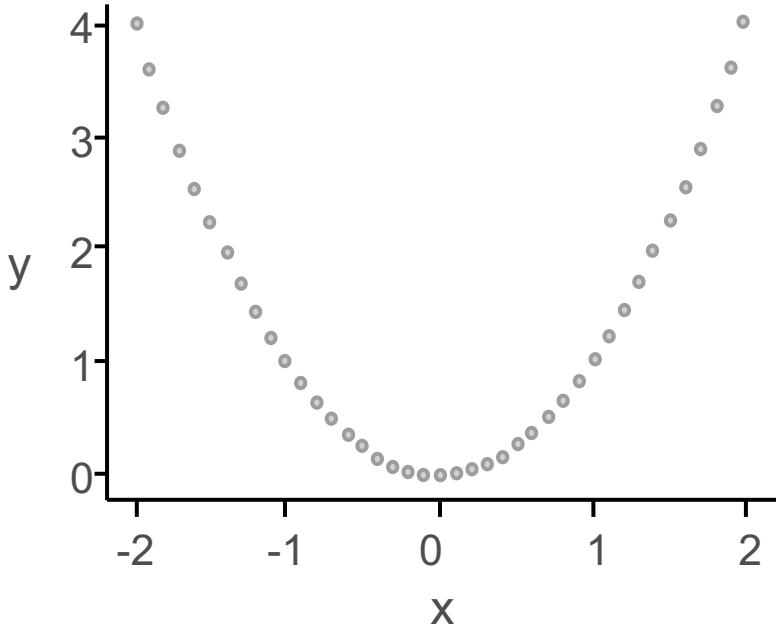
Wie groß ist hier der Korrelationskoeffizient?

a) $r \approx -1$

b) $r \approx 0$

c) $r \approx +1$

d) r kann nicht bestimmt werden.



© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: Nicht lineare Zusammenhänge

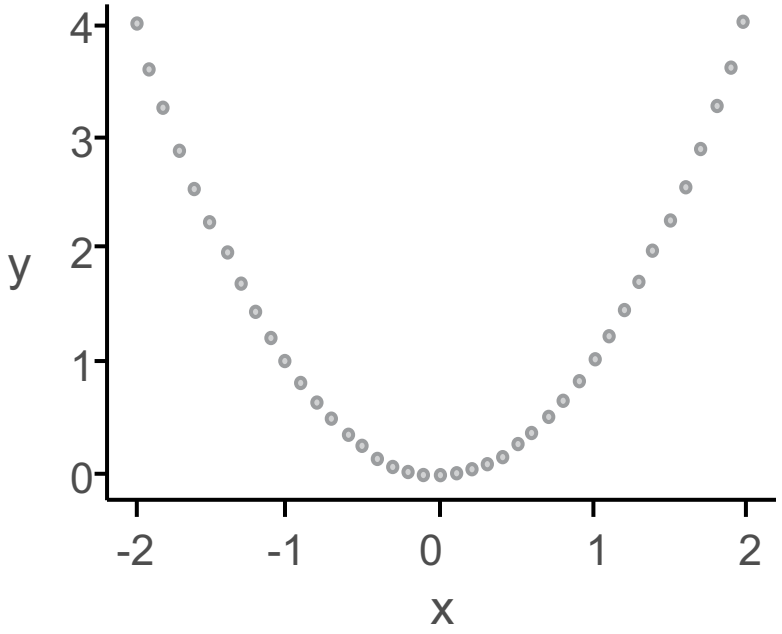
Wie groß ist hier der Korrelationskoeffizient?

a) $r \approx -1$

b) $r \approx 0$

c) $r \approx +1$

d) r kann nicht bestimmt werden.

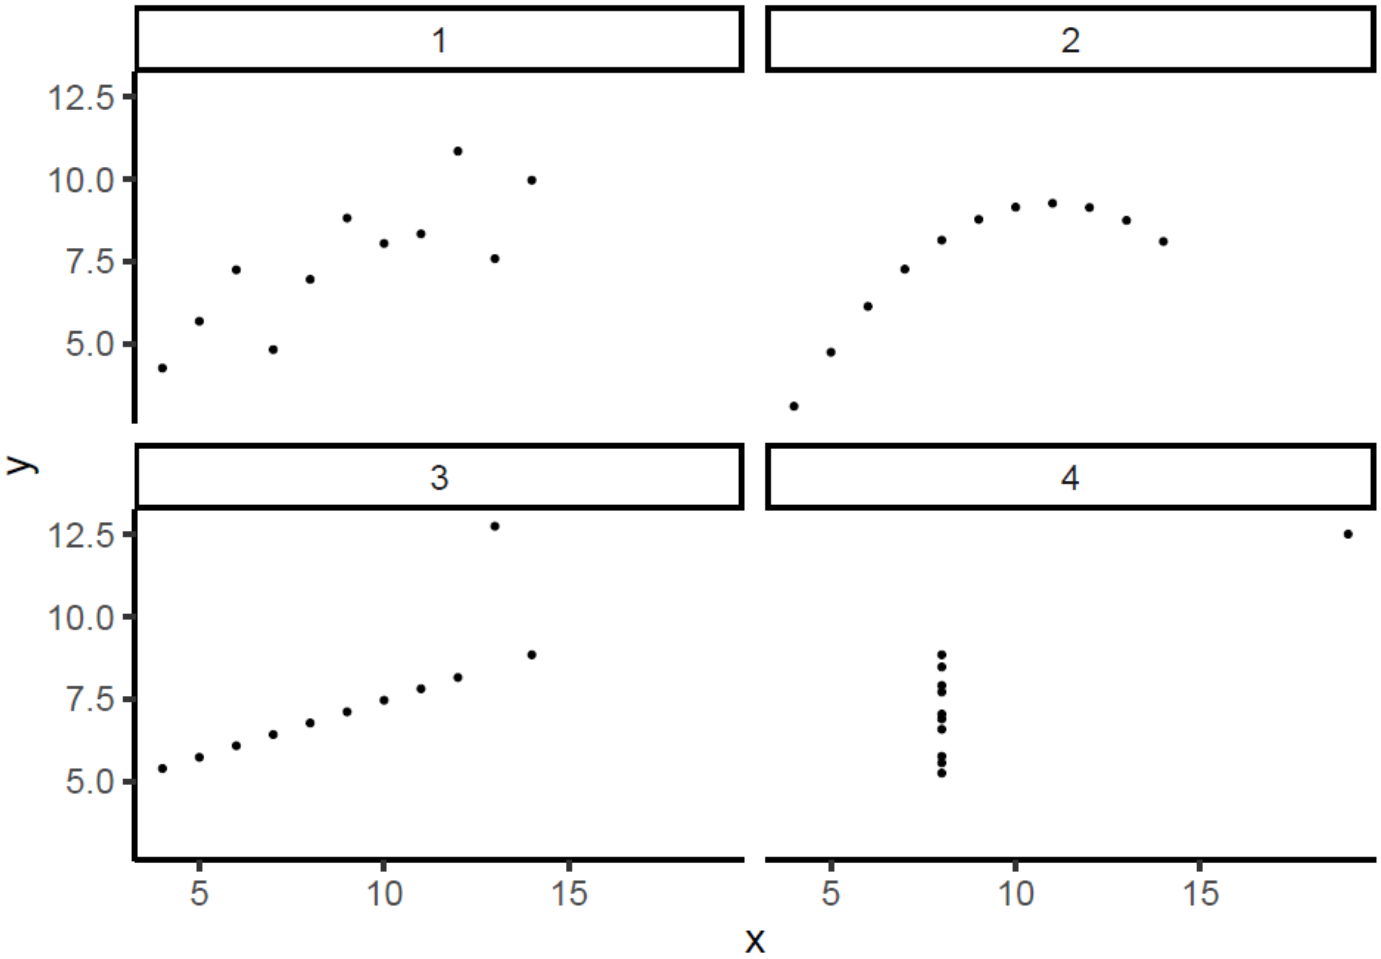


b),

… Der Korrelationskoeffizient misst nur lineare (d. h. insbesondere monotone) Zusammenhänge.
Hier gilt $y = x^2$, trotzdem ist $r \approx 0$: **Erst visualisieren, dann korrelieren.**

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Anscombe Quartett



© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Anscombe Quartett

- Die Verteilung von x und y unterscheidet sich sichtbar. Aber die deskriptiven Kennzahlen
  - $\bar{x} = 9;\ \bar{y} = 7{,}5$
  - $sd_x \approx 3{,}31;\ sd_y \approx 2{,}03$
  - $r \approx 0{,}82$

- sind nahezu identisch – in allen vier Fällen.[1]

- **Erst visualisieren, dann korrelieren!**

[1] Weiteres Beispiel z. B. unter https://www.autodeskresearch.com/publications/samestats

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
The Datasaurus Dozen

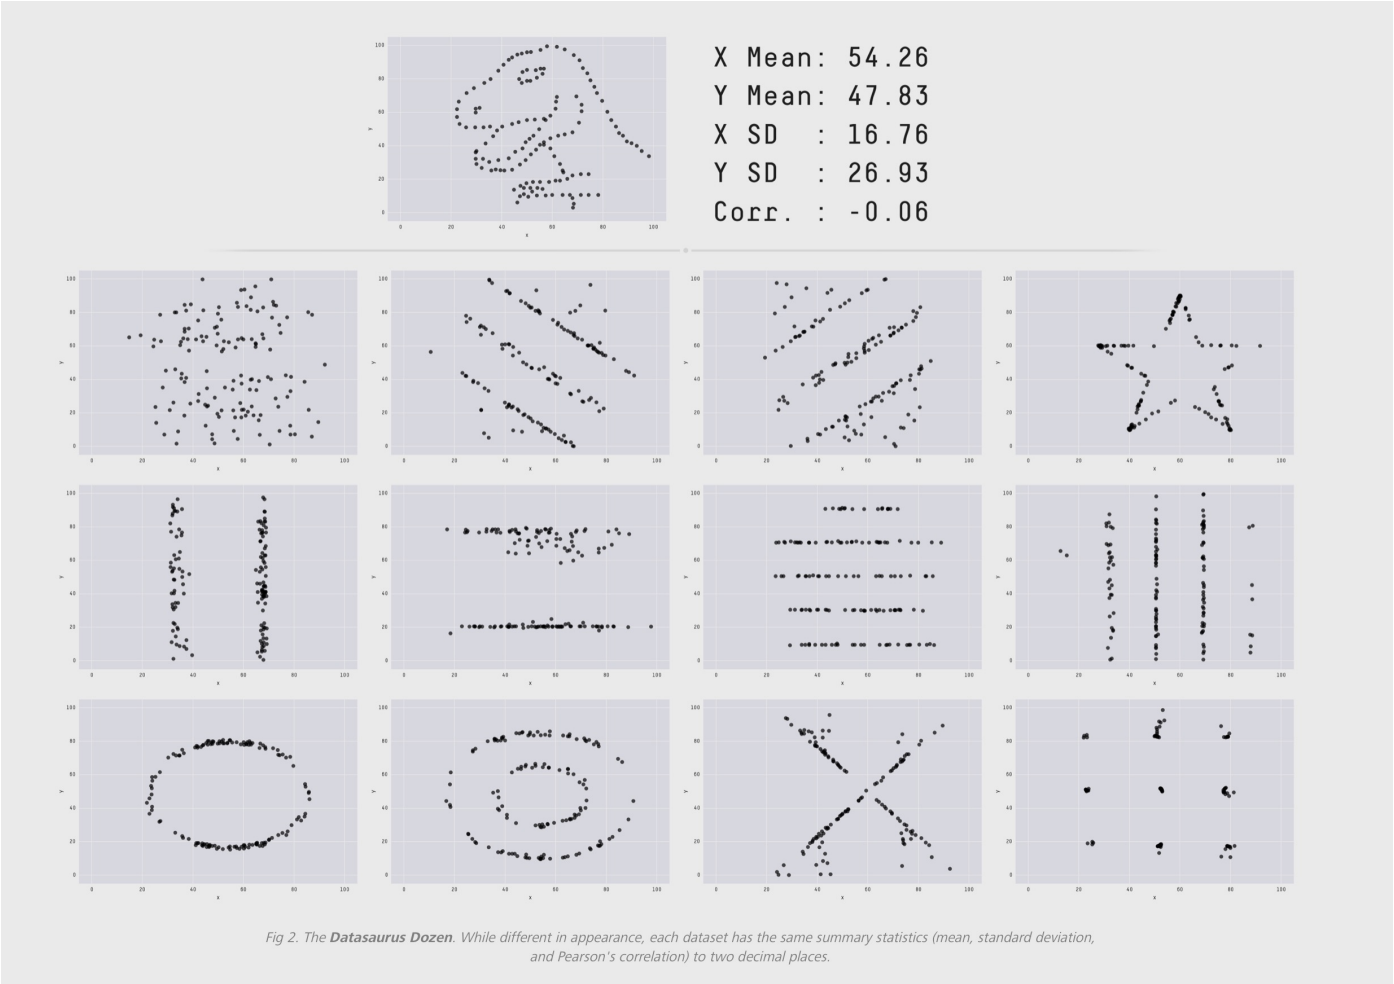


*Fig 2. The **Datasaurus Dozen**. While different in appearance, each dataset has the same summary statistics (mean, standard deviation, and Pearson's correlation) to two decimal places.*

Quelle: Autodesk Reseach, https://www.autodeskresearch.com/publications/samestats

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Korrelationskoeffizient

Stimmt die Aussage: **Der Korrelationskoeffizient ist robust gegen Ausreißer!**

a) Ja.

b) Nein.

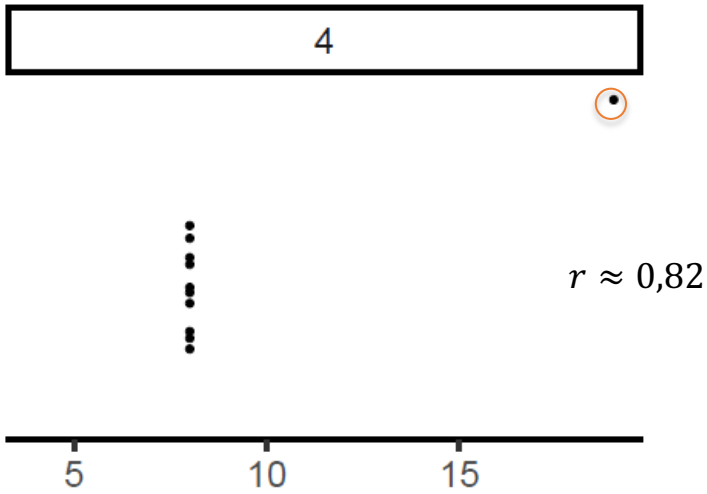
© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung Übung: Korrelationskoeffizient

Stimmt die Aussage: **Der Korrelationskoeffizient ist robust gegen Ausreißer!**

a) Ja.

b) Nein.



$r \approx 0{,}82$

b) Nein,

… wie Sie auch an der Graphik 4 des Anscombe-Quartett erkennen können, gibt es hier eigentlich gar keinen linearen Zusammenhang, dieser wird nur durch den einen Ausreißer vorgetäuscht.

Die Kovarianz (auf der der Korrelationskoeffizient beruht) ist wie die Varianz empfindlich gegen Ausreißer.

© 2026 – Hochschule der Bayerischen Wirtschaft

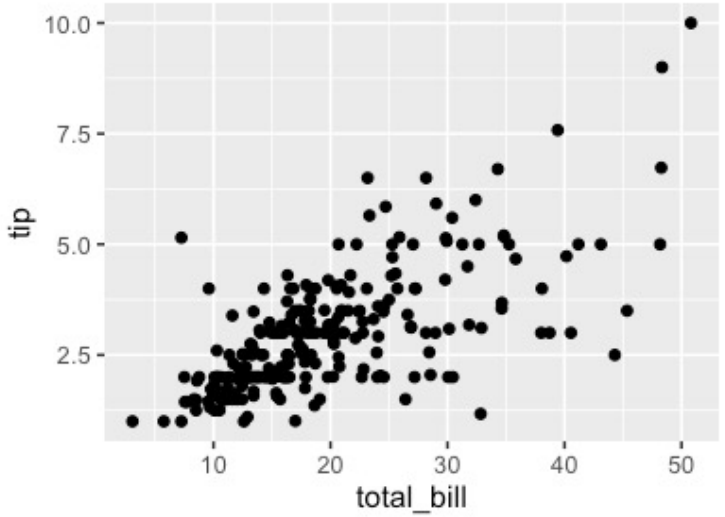
Explorative Datenanalyse
Übung: Zusammenhang Rechnungshöhe und Trinkgeld

Welche Aussage ist korrekt?

a) Es scheint keinen Zusammenhang zwischen Rechnungshöhe und Trinkgeld zu geben.

b) Es scheint einen negativen Zusammenhang zwischen Rechnungshöhe und Trinkgeld zu geben.

c) Es scheint einen positiven Zusammenhang zwischen Rechnungshöhe und Trinkgeld zu geben.



© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Lösung: Zusammenhang Rechnungshöhe und Trinkgeld

Welche Aussage ist korrekt?

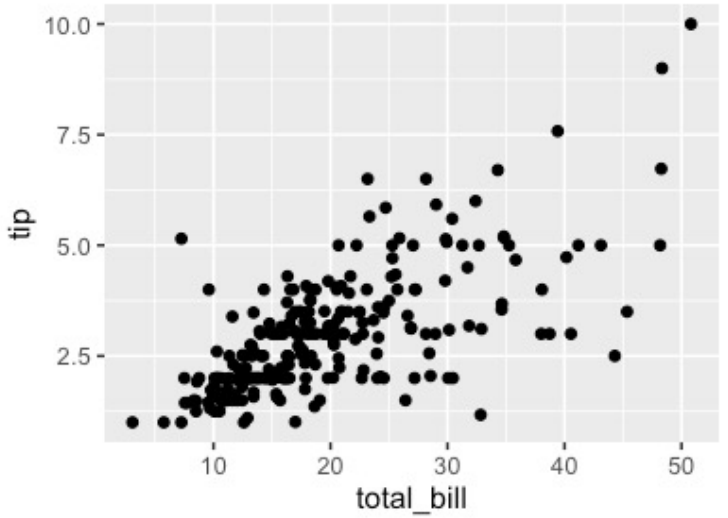
a) Es scheint keinen Zusammenhang zwischen Rechnungshöhe und Trinkgeld zu geben.

b) Es scheint einen negativen Zusammenhang zwischen Rechnungshöhe und Trinkgeld zu geben.

c) Es scheint einen positiven Zusammenhang zwischen Rechnungshöhe und Trinkgeld zu geben.

- Die Punktewolke erstreckt sich von links unten nach rechts oben, d. h., im Mittel werden bei größeren Rechnungsbeträgen auch die Trinkgelder höher.
  Antwort **c)** ist somit korrekt.

```
gf_point(tip ~ total_bill, data = tips)
```



© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Korrelation Rechnungshöhe und Trinkgeld

Analyse über Korrelationskoeffizienten:

```
cor(tip ~ total_bill, data = tips)
```

```
[1] 0.6757341
```


© 2026 – Hochschule der Bayerischen Wirtschaft

Offene Übung: Rechnungshöhe für Raucher bzw. Nichtraucher

- Was können Sie über die Verteilung der Rechnungshöhe für Raucher bzw. Nichtraucher aussagen?

© 2026 – Hochschule der Bayerischen Wirtschaft

Offene Übung: Rechnungshöhe für Raucher bzw. Nichtraucher

- Was können Sie über die Verteilung der Rechnungshöhe für Raucher bzw. Nichtraucher aussagen?

- Mit folgenden Befehlen können Sie eine explorative Datenanalyse vornehmen:

```
gf_histogram(~ total_bill | smoker, data = tips)
gf_boxplot(total_bill ~ smoker, data = tips)
favstats(total_bill ~ smoker, data = tips)
iqr(total_bill ~ smoker, data = tips)
```

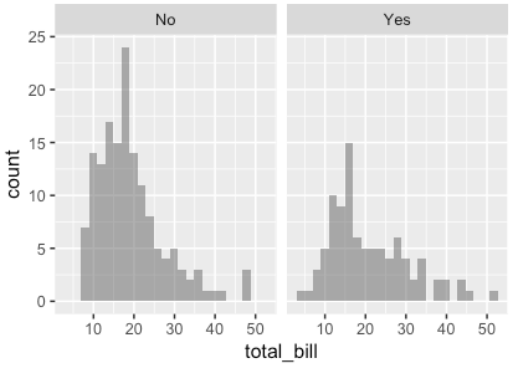

© 2026 – Hochschule der Bayerischen Wirtschaft

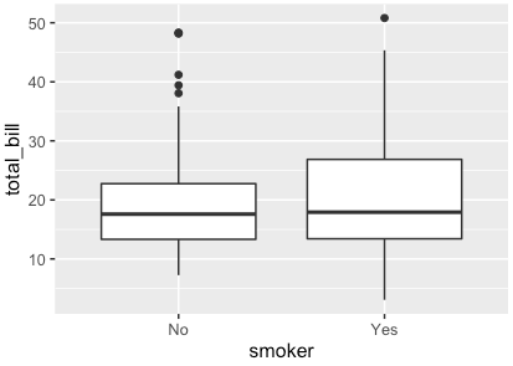
Offene Übung: Rechnungshöhe für Raucher bzw. Nichtraucher

- Was können Sie über die Verteilung der Rechnungshöhe für Raucher bzw. Nichtraucher aussagen?

```
  smoker  min     Q1 median     Q3   max     mean       sd   n missing
1     No 7.25 13.325  17.59 22.755 48.33 19.18828 8.255582 151       0
2    Yes 3.07 13.420  17.92 26.860 50.81 20.75634 9.832154  93       0
```

```
   No   Yes
9.43 13.44
```





- Beide Verteilungen sind rechtsschief (`gf_histogram`), bei den Nichtrauchern scheint es mehr Ausreißer zu geben (`gf_boxplot`).
- Im Mittel haben die Raucher eine etwas höhere Rechnungshöhe (`favstats`).
- Die Standardabweichung und der Interquartilsabstand (`iqr`) sind bei den Rauchern höher.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Analyse von Aktienkursen

- Mit den folgenden Befehlen können Kurse aus Yahoo Finance (andere Quellen siehe `?getSymbols` eingelesen werden,
  - Im folgenden beispielhaft die Apple Aktienkurse für den Zeitraum von 2007 bis 2021.
- Falls Sie das Paket quantmod noch nicht installiert haben, müssen Sie es einmalig mit dem Befehl `install.packages("quantmod", dependencies = TRUE)` installieren. Um das Paket zu laden, verwenden Sie den `library` Befehl, dieser muss bei jeder neuen R Sitzung aufgerufen werden.[1]

```
library(quantmod)
# Apple-Aktienkurse der letzten 15 Jahre aus Yahoo-Finance laden
getSymbols("AAPL", from = "2007-01-01", to = "2021-12-31")
```

[1] Wie bereits in früheren Kapiteln erwähnt, gelten diese Hinweise für alle anderen verwendeten Pakete ebenso.

© 2026 – Hochschule der Bayerischen Wirtschaft

Aufbau des Datensatzes

```
str(AAPL)
```

```
An ‘xts’ object on 2007-01-03/2021-12-30 containing:
  Data: num [1:3776, 1:6] 3.08 3 3.06 3.07 3.09 ...
 - attr(*, "dimnames")=List of 2
  ..$ : NULL
  ..$ : chr [1:6] "AAPL.Open" "AAPL.High" "AAPL.Low" "AAPL.Close" ...
  Indexed by objects of class: [Date] TZ: UTC
  xts Attributes:
List of 2
 $ src    : chr "yahoo"
 $ updated: POSIXct[1:1], format: "2022-05-02 10:13:14“
```

```
dim(AAPL)
```

```
[1] 3776    6
```

Es handelt sich um ein Zeitreihen-Objekt, ein sog. `xts` Objekt. Im Datensatz befinden sich 3776 Beobachtungen und 6 Variablen.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Analyse von Aktienkursen

Mit `names()` erhalten wir die Bezeichnungen der Variablen

```
names(AAPL)
```

```
[1] "AAPL.Open"     "AAPL.High"     "AAPL.Low"      "AAPL.Close"
[5] "AAPL.Volume"   "AAPL.Adjusted"
```

Da für uns nur der um Dividenden und Aktiensplits bereinigte Schlusskurs von Interesse ist, beschränken wir uns auf diese Variable. Im nächsten Schritt ändern wir den Namen der verbleibenden Variable auf `price`.

Es handelt sich um ein Zeitreihen-Objekt, ein sog. `xts`-Objekt. Im Datensatz befinden sich 3776 Beobachtungen und 6 Variablen.

```
# Beschränkung auf die adjustierten Schlusskurse
AAPL <- AAPL$AAPL.Adjusted
# Namensänderung auf price
names(AAPL)[1] <- "price"
```


© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Analyse von Aktienkursen

Kurzer Blick auf die ersten und letzten 6 Datenpunkte

```
head(AAPL)
```

```
                price
2007-01-03   2.562706
2007-01-04   2.619588
2007-01-05   2.600933
2007-01-08   2.613777
2007-01-09   2.830903
2007-01-10   2.966379
```

```
tail(AAPL)
```

```
                price
2021-12-22  175.4165
2021-12-23  176.0557
2021-12-27  180.1005
2021-12-28  179.0619
2021-12-29  179.1517
2021-12-30  177.9733
```

Mit `head(AAPL, n = …)` kann auch eine andere Anzahl ausgegeben werden.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Analyse von Aktienkursen

Zusätzlich zu den Kursen interessieren uns noch die Renditen, auf Basis derer wir die weiteren Analysen durchführen werden.

Wir können sowohl die diskrete als auch die stetige Rendite berechnen:

$$r_{t,diskret} = \frac{S_t}{S_{t-1}} - 1 \qquad r_{t,stetig} = \ln \frac{S_t}{S_{t-1}} = \ln S_t - \ln S_{t-1}$$

mit $r_{t,diskret}$ als der diskreten Rendite und $r_{t,stetig}$ als der stetigen Rendite, sowie dem Aktienkurs S_t zum Zeitpunkt t.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Analyse von Aktienkursen

Zumeist finden stetige (logarithmierte) Renditen Verwendung. Die lassen sich einfach über die Differenz des Logarithmus berechnen.

```
AAPL$return <- log(AAPL$price) %>% diff()
# Alternative: AAPL$return <- diff(log(AAPL$price))
head(AAPL)
```

```
              price       return
2007-01-03 2.562706           NA
2007-01-04 2.619588  0.021953322
2007-01-05 2.600933 -0.007146827
2007-01-08 2.613777  0.004926075
2007-01-09 2.830903  0.079799440
2007-01-10 2.966379  0.046746275
```

Für den ersten Zeitpunkt gibt es keinen Vortag, daher wird dieser Wert automatisch automatisch gleich `NA (Not Available)` gesetzt.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Analyse von Aktienkursen

Für die Grafiken benötigen wir folgende Pakete.[1]

```
library(ggformula)
library(gridExtra)
library(ggfortify)
```

Vor der grafischen Darstellung mittels der bekannten `mosaic`-Befehle werden die Zeitreihen in ein `data.frame` umgewandelt/abgespeichert.

```
# Als data.frame abspeichern und zusätzlich Variable date anlegen
AAPLdf <- as.data.frame(AAPL)
AAPLdf$date <- as.Date(row.names(AAPLdf))
# für price und return jeweils eine Grafik erzeugen
p1 <- gf_line(price ~ date, data = AAPLdf)
p2 <- gf_line(return ~ date, data = AAPLdf)
# untereinander anordnen
grid.arrange(p1, p2, ncol = 1)
```

[1] Ggf. sind sie noch über `install.packages("xxx", dependencies = TRUE)` zu installieren.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Analyse von Aktienkursen

Falls sie das Paket `ggfortify` installiert haben, gibt es eine Alternative:

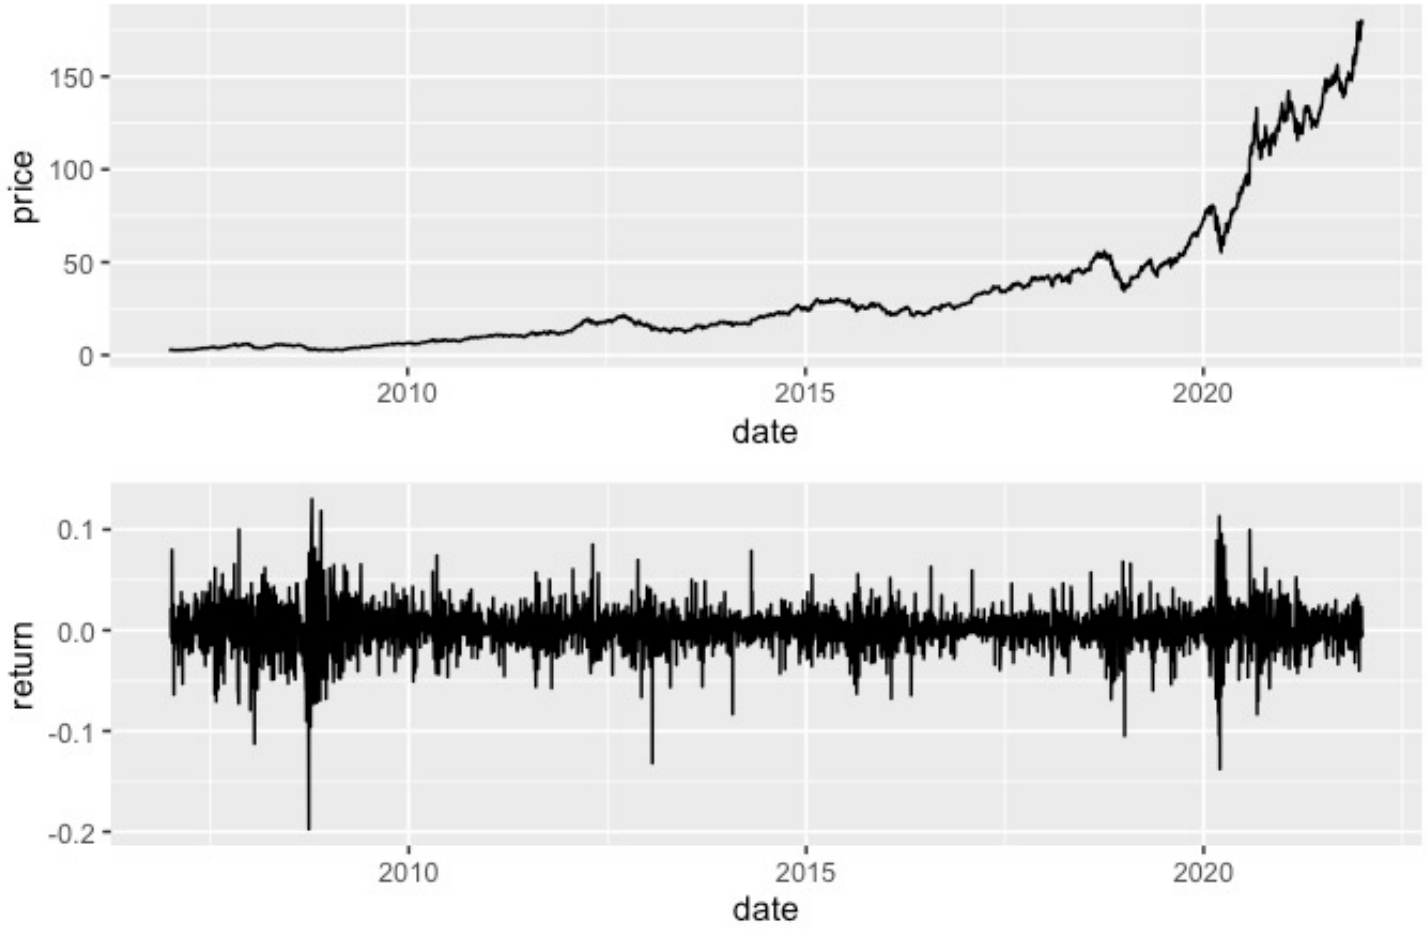
```
# für price und return jeweils eine Grafik erzeugen
p1 <- autoplot(price data = AAPL)
p2 <- autoplot(return, data = AAPL)
# untereinander anordnen
grid.arrange(p1, p2, ncol = 1)
```

oder

```
# für price und return jeweils eine Grafik erzeugen
p1 <- autoplot(AAPL$price)
p2 <- autoplot(AAPL$return)
# untereinander anordnen
grid.arrange(p1, p2, ncol = 1)
```


© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Analyse von Aktienkursen



© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übung: Analyse von Aktienkursen

Deskriptive Kennzahlen

- Im nächsten Schritt analysieren wir verschiedene deskriptive Kennzahlen der Kursveränderungen (Renditen) der Apple-Aktien.
- Vorab speichern wir diese als „normales“ Zeitreihenobjekt (`ts`) und entfernen die fehlenden Werte (damit die Kennzahlen berechnet werden können.

```
AAPL.return <- as.ts(na.omit(AAPL$return))
median(AAPL.return)
```

```
[1] 0.001117578
```

```
mean(AAPL.return)
```

```
[1] 0.00112333
```

```
sd(AAPL.return)
```

```
[1] 0.02026788
```

```
var(AAPL.return)
```

```
[1] 0.000410787
```


© 2026 – Hochschule der Bayerischen Wirtschaft

Deskriptive Kennzahlen

Alternativ dazu kann z. B. der Befehl `favstats` aus dem Paket `mosaic` verwendet werden:

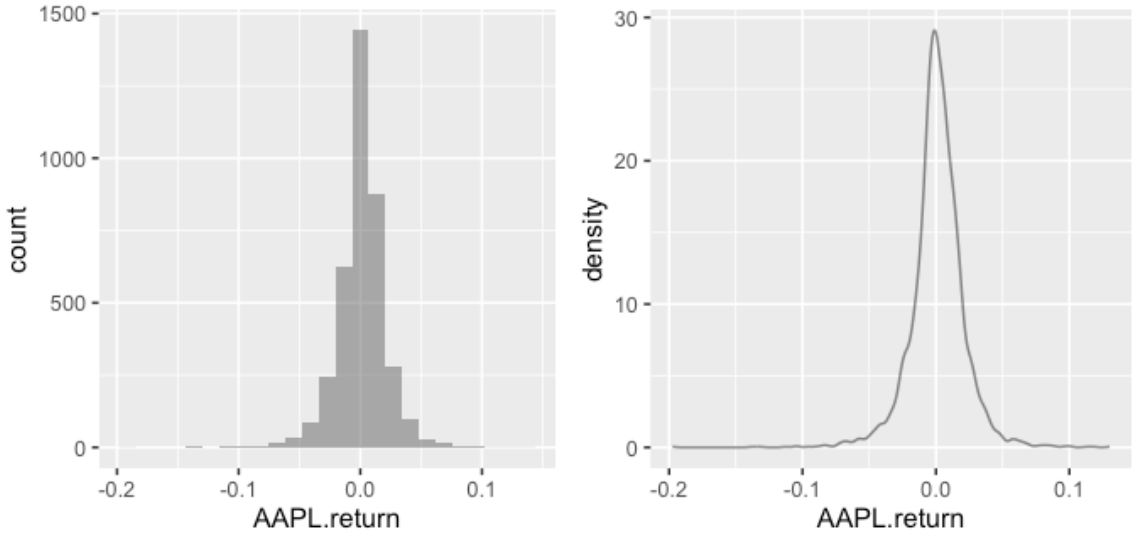
```
library(mosaic) # falls noch nicht erfolgt
favstats(AAPL.return)
```

```
        min           Q1      median          Q3       max        mean
-0.1974696 -0.00780183 0.001117578 0.01154456 0.1301941 0.00112333
         sd    n missing
0.02026788 3775       0
```


© 2026 – Hochschule der Bayerischen Wirtschaft

Histogramm und Dichteschätzung

```
p1 <- gf_histogram(~ AAPL.return)
p2 <- gf_dens(~ AAPL.return)
grid.arrange(p1, p2, nrow = 1)
```




```
# Alternativ in einem Plot
gf_dhistogram(~ AAPL.return)  %>% gf_dens(col = "blue")
```


© 2026 – Hochschule der Bayerischen Wirtschaft



Kapitel 4.5
Explorative Datenanalyse
Zusammenfassung

V26-10-25

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Visualisierung - Tipps

- Vermittle viele Zahlen, sonst brauchst du keine Grafik.
- Vermeide Ablenkung von der Hauptbotschaft.
- Fördere visuellen Vergleich.
- Unterschiedliche Farben nur, wenn es den Vergleich unterstützt.
- Vermeide 3D.
- Achte auf die Achsenskalierung.

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Grafische Verfahren der Datenanalyse

- **Säulendiagramm / Balkendiagramm:** Häufigkeit von Merkmalsausprägungen (nominal, ordinal, metrisch diskret) – `gf_bar(), gf_barh()`
- **Histogramm**: Häufigkeit von gruppierten Merkmalsausprägungen (metrisch) – `gf_histogram()`
- **Boxplot**: Visualisierung von Median, oberem und unterem Quartil, Minimum und Maximum, Ausreißern (metrisch) – `gf_boxplot()`
- **Violinplot**: Visualisierung der Dichtefunktion der Verteilung (metrisch) – `gf_violin()`
- **Streudiagramm** / **Scatterplot**: Darstellung der Merkmalsausprägungen von zwei i. d. R. metrischen Merkmalen [1] als Punkte – `gf_point()`
- **Mosaikplot**: Darstellung der Merkmalsausprägungen zweier nominaler Merkmale – `mosaicplot()`
- **Liniendiagramm**: Verlauf der Merkmalsausprägung eines Merkmals – `gf_line()`

© 2026 – Hochschule der Bayerischen Wirtschaft

Explorative Datenanalyse
Übersicht deskriptive Kennzahlen

- `favstats()`: Zusammenfassung Kennzahlen numerischer Variablen.
- Einzeln, z. B. mit:
    - `mean()`: Mittelwert (metrisch),
    - `median()`: Median (ordinal, metrisch),
    - `iqr()`: Interquartilsabstand ((ordinal), metrisch),
    - `sd()`: Standardabweichung (metrisch).
- `cor()`: Korrelationskoeffizient (zwei metrische Merkmale)
  Für ordinale Merkmale: Rangkorrelation `method = "spearman".`
- `prop()`: Anteile (nominal, ordinal, metrisch diskret – relative Häufigkeiten einer Ausprägung).
- `tally()`: (Kreuz-) tabellierung (nominal, ordinal, metrisch diskret – absolute oder relative Häufigkeiten aller Ausprägungen).

© 2026 – Hochschule der Bayerischen Wirtschaft